



**Universidad
Zaragoza**

**Aplicación de la inteligencia artificial usando
datos satelitales para el reconocimiento de
contaminación por exceso de nutrientes en
embalses**

**Artificial intelligence implementation using
satellite imagery for the identification of nutrient
excess contamination in reservoirs**

Trabajo Fin de Grado

Autor

José Miguel De La Ascensión

Director

Mario Esteban Suaza Medina

Ponente

F. Javier Zarazaga Soria

Escuela de Ingeniería y Arquitectura

2024/2025

Resumen

El objetivo central de este TFG ha sido desarrollar un modelo predictivo de la eutrofización basado en datos satelitales, con la finalidad de establecer las bases para la construcción de sistemas informáticos capaces de generar alertas de potenciales problemas en estas masas de agua. La metodología adoptada ha sido iterativa, abarcando fases de investigación sobre la viabilidad de indicadores de la eutrofización, adquisición y preprocesamiento de datos reales y la aplicación de diversas técnicas de aprendizaje automático.

Durante estas iteraciones se ha logrado automatizar la obtención de datos satelitales y estudiar en profundidad las posibilidades que dichos datos ofrecen en lo que al objetivo del trabajo respecta. Además, partiendo de datos reales de diversas fuentes se han creado conjuntos homogéneos con exactamente las características adecuadas para el entrenamiento y validación del modelo que se busca desarrollar.

A lo largo del desarrollo, la principal dificultad ha residido en la limitada disponibilidad de conjuntos de datos de mediciones reales y validadas, un factor que ha condicionado el rendimiento final de los modelos. Pese a estas dificultades, se han alcanzado varios modelos que cumplen con los requisitos funcionales establecidos. Entre estos, el análisis comparativo reveló que los algoritmos de *boosting* mostraron el mejor rendimiento, dada la naturaleza del problema y las restricciones de datos.

En conclusión, el objetivo de sentar las bases para un sistema predictivo de alertas ha sido logrado, aunque se reconoce que el rendimiento alcanzado presenta un amplio margen de mejora. De cara al futuro, se contempla la búsqueda activa de nuevos conjuntos de datos o la generación de datos sintéticos para potenciar la precisión de los modelos. La utilidad de este enfoque para optimizar los esfuerzos en el monitoreo de recursos hídricos vitales, especialmente en el contexto climático actual, subraya la relevancia de continuar explorando el potencial de la inteligencia artificial en este campo.

Todo el trabajo realizado, incluyendo el código fuente y los recursos pertinentes, está disponible públicamente en el repositorio: <https://github.com/ppmico/colabo-iza-thesis>.

Declaración de autoría



DECLARACIÓN DE AUTORÍA Y ORIGINALIDAD

(Este documento debe remitirse a seceina@unizar.es dentro del plazo de depósito)

TRABAJOS DE FIN DE GRADO / FIN DE MÁSTER

D./D^a. José Miguel De La Ascensión Doñate ,

en aplicación de lo dispuesto en el art. 14 (Derechos de autor) del Acuerdo de 11 de septiembre de 2014, del Consejo de Gobierno, por el que se aprueba el Reglamento de los TFG y TFM de la Universidad de Zaragoza,

Declaro que el presente Trabajo de Fin de Estudios de la titulación de Grado en Ingeniería Informática ☒ (Título del Trabajo)

Aplicación de la inteligencia artificial usando datos satelitales para el reconocimiento de contaminación por exceso de nutrientes en embalses / Artificial intelligence implementation using satellite imagery for the identification of nutrient excess contamination in reservoirs

es de mi autoría y es original, no habiéndose utilizado fuente sin ser citada debidamente.

Zaragoza, 27 de Junio de 2025

Fdo: José Miguel

Acknowledgements

Quisiera agradecer el logro que este trabajo ha supuesto primeramente al Dr. Mario Suaza, el director del trabajo, y al Dr. Javier Zarazaga, mi tutor. El trabajo con ellos ha sido siempre fluido y profesional, y en todo momento en el que he necesitado consejo o ayuda sus conocimientos y experiencia han estado a mi disposición. A ellos dos agradezco que el trabajo y sacrificio de elaborar un trabajo de esta magnitud haya sido resultado algo manejable.

A mi amigo Daniel quisiera agradecer haber despertado la curiosidad inicial que hizo que comenzase el trabajo con interés y ganas. Gracias a su infinito conocimiento sobre todo lo relacionado con el medio natural de nuestra tierra partí desde unos conocimientos previos privilegiados que me permitieron en todo momento trabajar con la seguridad de saber en qué estaba trabajando.

Además, a mi familia y amigos quiero agradecer el siempre haber comprendido mi concentración en los momentos en los que me tenía que dedicar al trabajo, permitiéndome silencio cuando trabajaba y consejo cuando lo necesitaba.

Por último, quisiera agradecer a Michael, mi anfitrión durante mi estancia en Berlín, la paciencia y comprensión que demostró dejando que ocupase su salón durante tantas horas trabajando en un documento que el ni podía comprender. Thanks a lot!

Índice general

1. Introducción	1
1.1. Contexto del Trabajo	1
1.2. Motivación, problema que se aborda y objetivo principal del proyecto	2
1.3. Alcance, objetivos y limitaciones	2
1.4. Tecnologías y herramientas de trabajo	3
1.5. Esquema general de la memoria del proyecto	4
2. Trabajo desarrollado	5
2.1. Aproximación metodológica seguida	5
2.2. Iteraciones	6
2.2.1. Iteración 1	6
2.2.2. Iteración 2	7
2.2.3. Iteración 3	10
2.2.4. Iteración 4	11
2.2.5. Iteración 5	13
2.2.6. Iteración 6	14
2.2.7. Iteración 7	16
2.2.8. Iteración 8	17
2.2.9. Iteración 9	19
2.2.10. Iteración 10	21
2.2.11. Iteración 11	23
2.2.12. Iteración 12	25
2.3. Aspectos más complejos abordados	27
2.4. Magnitud de los esfuerzos realizados	28
3. Lecciones aprendidas y conclusiones	29
3.1. Conocimientos adquiridos	29
3.2. Ideas futuras	29
3.3. Conclusiones	30
A. Análisis de la viabilidad del modelo objetivo	32
A.1. Selección de las fuentes de datos	32
A.1.1. Obtención de las lecturas satelitales	32
A.1.2. Obtención de valores de otros indicadores	33
A.2. Preprocesado de las imágenes satelitales	34
A.2.1. Filtrado de píxeles con nubes	34
A.2.2. Filtrado de píxeles sin agua	35
A.2.3. Descripción del algoritmo de filtrado global	36

A.3. Evaluación de los posibles indicadores	37
A.3.1. Estudio de cada periodo problemático	39
A.3.2. Estudio correlacional de cada banda	39
A.3.3. Estudio de la temperatura como indicador	43
A.3.4. Estudio de las combinaciones de bandas más reveladoras	45
A.3.5. Pruebas mezclando combinaciones de bandas con temperaturas	46
B. Desarrollo del modelo de clasificación	56
B.1. Obtención y preprocesamiento de conjunto de datos para entrena- miento	56
B.1.1. Dataset 1. Pruebas y conclusiones	57
B.1.2. Dataset 4. Pruebas y conclusiones	59
B.2. Estudio de modelos de IA candidatos	61
B.3. Selección de modelos validando con el embalse de El Val	62
B.4. Optimización de hiperparámetros	63
Bibliografía	65

1. Introducción

1.1. Contexto del Trabajo

El monitoreo de nutrientes es clave para la gestión de grandes embalses destinados al consumo de agua, ocio y preservación de la biodiversidad; un exceso de nutrientes (fenómeno conocido como *eutrofización*), provocado a menudo por la actividad humana, puede resultar en floraciones (o *blooms*) de **cianobacterias** con una variedad de consecuencias negativas desde la **pérdida de biodiversidad** hasta la pérdida de la calidad del agua para uso humano.

Mientras se prevé que la distribución y frecuencia de estas floraciones aumentará en los próximos años, los actuales métodos predominantes de monitorización de embalses para detectar estos problemas siguen siendo medidas *in-situ* de concentraciones de nutrientes y cianobacterias. Estas aproximaciones, aunque precisas, requieren una considerable inversión de recursos humanos (viajes a los embalses para toma de muestras, análisis de las mismas, etc) y no son fácilmente escalables.

Con carácter general, las entidades gestoras de estas infraestructuras (en España, las Confederaciones Hidrográficas) suelen programar trabajo de campo **periódico** destinado a evaluar el estado de las mismas. De este modo, técnicos de las entidades viajan cada cierto tiempo a los embalses para efectuar las tomas de muestras. Estos viajes suelen hacerse atendiendo a planificaciones de trabajo más que a conocimiento sobre la realidad que tienen en ese momento las masas de agua. Un problema que suele presentarse es que se identifica un exceso de nutrientes cuando estos ya están muy altos y, por tanto, se reducen las posibilidades de atajar esta situación de manera temprana.

Por otro lado, la teledetección satelital es una técnica que permite observar y analizar la superficie terrestre desde el espacio mediante sensores remotos. Esta tecnología es clave para el monitoreo ambiental, la agricultura, la gestión del agua y la detección de desastres naturales. Un ejemplo destacado de recursos disponibles son la constelación Sentinel-2 del programa Copernicus de la Unión Europea. Con dos satélites (Sentinel-2A y 2B), ofrece imágenes multiespectrales de alta resolución con una frecuencia de revisita de hasta 5 días. Sus 13 bandas espectrales permiten analizar vegetación, suelos, cuerpos de agua y cambios en el uso del suelo, proporcionando datos gratuitos y abiertos para científicos, gobiernos y ciudadanos.

1.2. Motivación, problema que se aborda y objetivo principal del proyecto

Tal y como se ha indicado, la aproximación habitual que se sigue para el monitoreo de la calidad de las aguas es el seguimiento *in-situ* del estado de los embalses a través de la planificación de trabajos de toma de muestras y análisis de las mismas. Esto, como ya se ha expuesto, supone un alto consumo de recursos, a la par que no garantiza una identificación temprana de los problemas. Frente a esta situación, el presente trabajo se fija como objetivo inicial el **desarrollo de un modelo predictivo de la eutrofización que pueda servir de base para la construcción de sistemas informáticos capaces de generar alertas de potenciales problemas en grandes masas de agua.**

1.3. Alcance, objetivos y limitaciones

El alcance del trabajo que se expone en esta memoria está acotado a **la especificación de un modelo predictivo, identificación de los recursos de información** que podrían ser **la base con la que trabajaría este modelo, entrenamiento del mismo y validación** en un entorno que avale que el modelo puede servir para conseguir el objetivo buscado. **Queda fuera del alcance de este TFG el desarrollo de ningún tipo de prototipo de sistema de monitorización y alarma que pueda basarse en el modelo especificado.** Para ello, se deberá emplear lecturas satelitales con el fin de reconocer y predecir el estado trófico de un embalse, clasificándolo en base a los cuatro niveles de alerta establecidos por la Organización Mundial de la Salud (OMS) para concentraciones de cianobacterias (figura 1.1)

AG. CONSUMO-BAÑO	DENSIDAD ALGAL CIANOB. (cel/mL)	BIOVOLUMEN CIANOB. (mm3/L)	CLOROFILA A CIANOB. (µg/L)	FICOCIANINA CIANOB. (µg/L)
VIG	200	0.02	0.1	0.1
ALERTA I –AMARILLO-	2000	0.2	1	4
ALERTA I –NARANJA-	20.000	2	10	30
ALERTA II	100.000	10	50	90

Figura 1.1.: Valores guía de la OMS para cianobacterias en aguas destinadas a la producción de agua de consumo humano y en aguas de baño (Chorus y Bartram, 1999)

El estudio se centrará inicialmente en **el embalse de El Val** (en el término municipal de Tarazona, provincia de Zaragoza), donde la Confederación Hidrográfica del Ebro (CHE) ha registrado concentraciones de cianobacterias superiores a 20.000 células/mL (nivel de 'ALERTA I -NARANJA-' según la OMS) en julio de 2018, julio de 2020 y septiembre de 2020. Estos episodios y medidas servirán como referencia para validar la eficacia del modelo.

1.4. Tecnologías y herramientas de trabajo

El desarrollo de este proyecto ha requerido la implementación de diversas tecnologías y herramientas para el procesamiento de datos satelitales, el desarrollo de algoritmos de aprendizaje automático y la visualización de resultados. A continuación, se detallan las principales:

Para el desarrollo y ejecución del código, se ha optado por un entorno de trabajo completamente basado en la nube: **Google Colaboratory**¹. Esta plataforma ha permitido alojar y ejecutar todo el código en la nube, se ha trabajado con **Jupyter Notebooks**, ampliamente utilizados en ciencia de datos y que combinan código, texto explicativo, visualizaciones y ecuaciones en un único documento.

Un pilar fundamental para el acceso y procesamiento de los datos satelitales ha sido la **plataforma Sentinel Hub**². Se ha hecho uso extensivo de su **API** (*Application Programming Interface*) para la descarga programática de imágenes satelitales, así como de sus herramientas web para la visualización y análisis exploratorio. Adicionalmente, se han empleado **Sentinel Hub EO Browser**³ y el **Copernicus Browser**⁴ como herramientas gráficas para la exploración, visualización y análisis preliminar de los datos geoespaciales que pudieran ser de utilidad para este trabajo.

El lenguaje de programación principal empleado en este proyecto ha sido Python⁵, y se ha hecho uso del extenso ecosistema de librerías públicamente disponibles. Entre otras, se han empleado las librerías *sentinelhub*⁶, para la interacción directa con la API de Sentinel Hub, permitiendo la descarga y preprocesamiento de datos satelitales; *szcloudless*⁷: para la detección de nubes en imágenes Sentinel-2, lo que ha permitido filtrar los datos y asegurar la calidad de las observaciones; *sklearn* (*scikit-learn*)⁸, *optuna*⁹, *hyperopt*¹⁰, *xgboost*¹¹, *tensorflow*¹² y *keras_tuner*¹³, para el entrenamiento y optimización de modelos de aprendizaje automático, entre otras funciones relacionadas con el desarrollo del modelo objetivo; y más librerías con funcionalidades diversas funcionalidades particulares, como *shapely*¹⁴, *numpy*¹⁵, *pandas*¹⁶, *matplotlib*¹⁷ o *requests*¹⁸.

¹<https://colab.research.google.com>

²<https://www.sentinel-hub.com/>

³<https://apps.sentinel-hub.com/eo-browser/>

⁴<https://browser.dataspace.copernicus.eu/>

⁵<https://www.python.org/>

⁶<https://sentinelhub-py.readthedocs.io/en/latest/>

⁷<https://pypi.org/project/szcloudless/>

⁸<https://scikit-learn.org/stable/>

⁹<https://optuna.org/>

¹⁰<https://hyperopt.github.io/hyperopt/>

¹¹<https://xgboost.readthedocs.io/en/stable/>

¹²<https://www.tensorflow.org/>

¹³https://keras.io/keras_tuner/

¹⁴<https://shapely.readthedocs.io/en/stable/index.html>

¹⁵<https://numpy.org/>

¹⁶<https://pandas.pydata.org/>

¹⁷<https://matplotlib.org/>

¹⁸<https://pypi.org/project/requests/>

1.5. Esquema general de la memoria del proyecto

El resto de la memoria de este Trabajo Final de Grado incluye las siguientes secciones:

- **Sección 2:** En este capítulo se hace un amplio resumen del trabajo desarrollado, incluyendo detalles de aquellas actividades que mayor relevancia han tenido en la consecución de los objetivos del proyecto. Así mismo, se resaltan los aspectos que han sido más complejos de abordar. Este capítulo incluye también un breve análisis de la dimensión del trabajo desarrollado.
- **Sección 3:** Este capítulo presenta un resumen de los conocimientos adquiridos más destacados, las posibles líneas de ampliación del trabajo desarrollado, y, finalmente, unas conclusiones globales del proyecto.
- **Bibliografía:** Este anexo incluye las referencias bibliográficas usadas en todo el documento.
- **Anexo A:** Este anexo recoge en detalle el estudio realizado para determinar los medios de obtención y procesamiento de datos satelitales y de otra índole. A continuación se presenta un análisis exploratorio de la adecuación de dichos datos como posibles indicadores de eutrofización con el fin de identificar la fuente de datos adecuada para el modelo a desarrollar.
- **Anexo B:** En este anexo se detalla el proceso de obtención y preprocesamiento de datos reales que cumplan con los requisitos determinados en el anexo anterior, que se usarán para el entrenamiento del modelo a desarrollar. Además, se recoge el proceso de selección de posibles técnicas de aprendizaje automático ya existentes para resolver el problema, pasando por el entrenamiento, validación y optimización de varios modelos candidatos a ser el modelo buscado.

2. Trabajo desarrollado

2.1. Aproximación metodológica seguida

Este trabajo se planteó para ser desarrollado en iteraciones de 2 semanas de calendario (con una dedicación compatible con cursar asignaturas de 4º) en las que se han ido proponiendo hipótesis de trabajo y/o objetivos a conseguir. Al final de cada iteración se ha efectuado un trabajo de evaluación de los resultados obtenidos y se ha diseñado el trabajo para una nueva iteración. Estas iteraciones han perseguido ajustar de manera granularmente el tiempo dedicado al TFG con el fin de abordar tres grandes fases:

Recolección y preparación de datos para el entrenamiento del modelo: En primer lugar se seleccionarán las bandas espectrales (o combinaciones de las mismas) que presentan cambios significativos antes y durante los episodios de eutrofización registrados por la CHE en el embalse de El Val. El modelo empleará el valor de estos indicadores en el embalse que se desee como entrada.

Una vez determinados los indicadores más adecuados, se han obtenido lecturas de dichos indicadores correspondientes a masas de agua distintas al embalse de El Val para los cuales se disponga también de datos sobre concentraciones de cianobacterias en las mismas fechas. Este conjunto de datos servirá como corpus de entrenamiento etiquetado, con la intención de que el modelo aprenda a reconocer la concentración de cianobacterias en un embalse dadas las lecturas satelitales.

Asimismo, se ha considerado la inclusión de variables complementarias, como temperatura, presión atmosférica y volumen de agua embalsada, con el fin de enriquecer el conjunto de datos y mejorar la capacidad predictiva del modelo.

Diseño y entrenamiento del modelo: Se han entrenado y optimizado varios modelos de inteligencia artificial usando los datos ya procesados y una variedad de técnicas de aprendizaje automático ya existentes, empleando varias métricas comunes para determinar el modelo más apropiado.

Validación y ajuste: Finalmente, se ha procedido a la evaluación del modelo con los casos de eutrofización del embalse de El Val registrados por la CHE y reajuste de parámetros en caso de ser necesario para mejorar su precisión predictiva de manera reiterada.

La siguiente sección presenta los aspectos más relevantes de las iteraciones llevadas a cabo durante este proyecto. De manera complementaria, en los anexos se ofrece un mayor nivel de detalle sobre estas iteraciones.

2.2. Iteraciones

2.2.1. Iteración 1

Objetivos:

En esta iteración se tiene como objetivos el estudio de las posibles fuentes de datos satelitales, así como abordar el desafío de las áreas secas y la presencia de nubosidad en dichos datos satelitales, ya que un área con estas condiciones, aunque quede dentro del perímetro del embalse, no proporciona información útil sobre el estado del agua del embalse, información esencial para la predicción temprana de la eutrofización.

Desarrollo:

Durante esta iteración, se investigan a fondo las principales fuentes abiertas de información satelital adecuadas para el monitoreo de embalses. Se estudian detenidamente las misiones **Landsat** de la USGS (*United States Geological Survey*)¹ y **Sentinel-2**² del programa *Copernicus* de la ESA (Agencia Espacial Europea), así como fuentes de lecturas satelitales comerciales como Airbus³.

Tras un análisis detallado, cuyas principales conclusiones se recogen en la tabla 2.1, se concluye que la misión **Sentinel-2** es la más apropiada para los fines de este trabajo, principalmente debido a su resolución espacial y temporal superior, que permite un monitoreo más frecuente y detallado de las variaciones en la superficie del agua.

Una vez determinada la fuente de datos satelitales a emplear se procede a abordar la extracción de información relevante de dichos datos satelitales, para lo que se presentan dos desafíos principales: la **detección y enmascaramiento de nubes** y la **identificación de las superficies secas**. Para la detección de nubes, se investigan diversas aproximaciones, entre las que están las **capas preprocesadas CLM** (*cloud masks*) y **CLP** (*cloud probabilities*)⁴ de SentinelHub, las máscaras preprocesadas **L2A scene classification data**^{5 6}, la **librería s2cloudless de Python**⁷, el algoritmo **Braaten-Cohen-Yang cloud detector**⁸, o el **Hollstein's cloud detection algorithm**⁹.

En cuanto a la delimitación de las masas de agua, se estudia inicialmente el índice **mNDWI** (*modified Normalized Difference Water Index*), una versión más moderna del índice **NDWI** (*Normalized Difference Water Index*) el cual es la opción

¹<https://landsat.gsfc.nasa.gov/>

²<https://www.sentinel-hub.com/>

³Más información en la [página de Airbus](#)

⁴Más información en la [documentación](#)

⁵Más información en la [wiki de la ESA](#)

⁶Hay una [publicación en el foro de Sentinel Hub](#) al respecto

⁷Véase el [repositorio en Github](#)

⁸Para implementarlo más información [aquí](#)

⁹Implementación en el [repositorio de Github](#)

2. Trabajo desarrollado

Tabla 2.1.: Comparación de características clave entre Sentinel-2 y Landsat-8

Característica	Misión Sentinel 2	Misión Landsat 8
Resolución espacial más precisa	10m	30m
Resolución temporal (tiempo de revisita del mismo punto):	5 días	16 días
Disponibilidad de datos	≈ 1500 imágenes al día libremente disponibles usando el Copernicus Data Space Ecosystem	≈ 700 imágenes al día disponibles de manera libre a través de USGS EarthExplorer

Tabla: comparación de Sentinel y Landsat ^{a b c}

^aFuente 1: <https://www.sentinel-hub.com/>

^bFuente 2: <https://landsat.gsfc.nasa.gov/>

^cFuente 3: <https://www.usgs.gov/>

por defecto para la detección de agua en teledetección. Sin embargo, tras realizar algunas pruebas, se concluye que el trabajo requerido para resolver las dificultades originadas de usar el mNDWI no compensan la mejora que aporta, y el NDWI ofrece un rendimiento suficientemente robusto y consistente.

Resultados:

Tras el estudio realizado se ha establecido que Sentinel-2 será la principal fuente de datos satelitales, justificado por su resolución espacial y temporal adecuada para el seguimiento de fenómenos en embalses. Como se ha explicado se ha decidido emplear **el índice NDWI** para la identificación de áreas secas dentro de los embalses, y la librería `s2cloudless` de Python para el filtrado de píxeles con nubes, seleccionada por su alto rendimiento y sencilla integración. Estos resultados proporcionan una base sólida para las siguientes fases del proyecto.

2.2.2. Iteración 2

Objetivos:

El objetivo principal de esta iteración es automatizar la solicitud de imágenes satelitales y su filtrado, con los objetivos en mente de facilitar la obtención de datos de teledetección durante el resto del trabajo y de garantizar que el producto de esta investigación pueda en un futuro usarse para el desarrollo de sistemas de alarma de eutrofización también automáticos. En cuanto al filtrado se busca seleccionar únicamente aquellos píxeles en las imágenes satelitales **que no presentan nubosidad y que corresponden a áreas con agua**. Esto es crucial para asegurar la calidad y pertinencia de los datos de entrada para los modelos de aprendizaje automático.

Trabajo Desarrollado:

Para lograr la automatización, se implementa la función `ApiReqRez`, que abstrae la complejidad de las solicitudes a la API de Sentinel Hub. Esta función permite obtener la información satelital de un embalse específico para una fecha y fuente de datos (e.g. satélite sentinel-L2A) determinada, dada la información geométrica y geográfica del pantano, así como la naturaleza de los datos solicitados, especificada mediante un *evalscript*¹⁰.

Además, se desarrolla el algoritmo de filtrado [1](#) de imágenes satelitales diseñado para minimizar el número de solicitudes a la API de Sentinel Hub. Este enfoque es fundamental, ya que las solicitudes a la API representan el principal cuello de botella del proyecto, tanto por el tiempo de ejecución como por el coste computacional y potencialmente económico asociado. El algoritmo prioriza la verificación de la validez de los píxeles (ausencia de nubes y presencia de agua) antes de solicitar la información de todas las bandas espectrales o sus combinaciones (en otras palabras, la información satelital buscada), dado que estas solicitudes son las más exigentes computacionalmente.

¹⁰Más sobre los *evalscript* en la [documentación](#)

Algorithm 1 Solicitud y filtrado las lecturas satelitales de varias fechas

Require: L_f , lista de fechas en las que exista una lectura satelital de la constelación Sentinel-2 del AOI del embalse de interés.

Require: ' minPrctgPx ' $\in (0, 1]$, mínimo porcentaje de píxeles sin nubes y con agua que debe tener una imagen satelital para ser considerada como relevante para el estudio.

Require: ' dataMask ', máscara de datos del embalse de interés con valores $\neq 0$ sólo dentro del perímetro del embalse.

Ensure: Una lista (L_s) que contiene únicamente las lecturas satelitales tomadas en alguna de las fechas dadas en ' L_f ' que tienen más de un ' minPrctgPx ' % de píxeles válidos.

```

1:  $L_s \leftarrow \emptyset$  ▷ Se inicializa vacía la lista de lecturas válidas
2:  $\text{min}_{px} \leftarrow$  numero de valores distintos de 0 en  $\text{dataMask}$ 
3:  $\text{min}_{px} \leftarrow \text{min}_{px} \times \text{minPrctgPx}$ 
4: for all fecha en  $L_f$  do
5:    $\text{mascara\_nubes} \leftarrow \text{ApiReqRez}(\text{evalscript\_nubes})$ 
6:   if # valores en  $\text{mascara\_nubes}$  distintos de 0  $\geq \text{min}_{px}$  then
7:      $\text{mascara\_agua} \leftarrow \text{ApiReqRez}(\text{evalscript\_agua})$ 
8:      $\text{mascara\_nubesyagua} \leftarrow \text{mascara\_agua} \times \text{mascara\_nubes}$ 
9:     if # valores en  $\text{mascara\_nubesyagua}$  distintos de 0  $\geq \text{min}_{px}$  then
10:       Se añade el resultado de  $\text{ApiReqRez}(\text{evalscript\_bandas})$  a  $L_s$ 
11:     else
12:       Se descarta fecha y continua a la siguiente iteración
13:     end if
14:   else
15:     Se descarta fecha y continua a la siguiente iteración
16:   end if
17: end for
18: if  $L_s$  está vacía then
19:   return "No se encontraron imágenes válidas."
20: else
21:   return  $L_s$ 
22: end if

```

Resultados:

Las pruebas exhaustivas con los métodos de filtrado y la implementación de ApiReqRez demuestran la viabilidad de automatizar la adquisición y el preprocesamiento de datos satelitales. El algoritmo de filtrado global asegura que solo se procesen las imágenes con un porcentaje suficiente de píxeles válidos, optimizando el uso de los recursos de la API. Este proceso establece una base sólida para la posterior evaluación de indicadores de eutrofización y el entrenamiento de modelos de aprendizaje automático.

2.2.3. Iteración 3

Objetivos:

El presente estudio se centra en el embalse de El Val, donde se registraron tres eventos de eutrofización detectados **el 4 de julio de 2018, el 10 de julio de 2020 y el 10 de septiembre de 2020**, según los datos proporcionados por la Confederación Hidrográfica del Ebro (CHE) (ver figura [A.1](#)). El objetivo de esta iteración es representar gráficamente la evolución de las reflectancias de todas las bandas espectrales a lo largo de 3 'periodos de interés' para realizar un análisis visual en busca de indicadores de eutrofización. Cada periodo abarca desde tres meses antes hasta un mes después de la detección de uno de los mencionados eventos de eutrofización detectados en el embalse de El Val. El análisis visual posterior busca identificar picos o alteraciones significativas en la reflectancia de alguna de las bandas entorno al evento de eutrofización, con el fin de establecer una banda que sirva como indicador de este fenómeno.

Desarrollo:

Se implementa la función `curvasEnFechas` en el *notebook* `estudio_indicadores`, que constituye la implementación con adaptaciones del algoritmo de filtrado [1](#). Esta función se encarga de almacenar los resultados de la solicitud de lecturas de las bandas espectrales en un *DataFrame*, con el que, haciendo uso de los métodos de la clase *DataFrame*, se graficará la reflectancia promedio de cada banda en función de la fecha. En [A.3](#) se explica en más detalle cómo se puebla esta estructura de datos.

Al generar estas representaciones, resulta común que un número considerable de imágenes satelitales sean **descartadas** por el algoritmo debido a que no cumplen con el porcentaje mínimo de píxeles válidos (libres de nubosidad o con presencia de agua). La consecuente ausencia de datos en diversas fechas interrumpe la delineación completa de las curvas y **dificulta su análisis visual**. Para mitigar este efecto, se opta por emplear la interpolación *spline* de orden 2¹¹. Esta elección se justifica por la capacidad de dicha interpolación de generar curvas más suaves en comparación con la interpolación lineal, mientras que el uso de polinomios de grado 2 evita una complejidad excesiva. Dada la variabilidad no extrema que se prevé en las curvas de reflectancia, se prioriza una alteración mínima de los datos originales.

¹¹Para más detalles sobre la interpolación *spline*, consúltase la [Wikipedia](#)

2. Trabajo desarrollado




Figura 2.1.: Curvas de evolución en cada banda sin y con interpolación, con una línea vertical roja marcando la detección de la eutrofización por parte de la CHE

Resultados:

Las tres representaciones gráficas resultantes, ver 2.1, sugieren visualmente que las bandas 3 y 9 exhiben incrementos significativos en las proximidades de las fechas de detección de eutrofización. No obstante, este indicio no es suficientemente claro y a pesar de que además todas las bandas muestran un pico durante la detección del tercer evento, no se alcanza ninguna conclusión definitiva. Esta ambigüedad justifica la necesidad de realizar pruebas adicionales para confirmar la viabilidad de estas bandas como indicadores de eutrofización.

Dicho esto, se decide integrar la interpolación a la generación del resto de gráficas del trabajo, dado su funcionamiento satisfactorio en esta prueba.

2.2.4. Iteración 4

Objetivos:

Esta iteración tiene por objetivo analizar la evolución de las reflectancias de cada banda espectral, así como del Índice de Vegetación de Diferencia Normalizada


(NDVI), a lo largo de cuatro periodos de interés específicos: del **4 de mayo al 4 de agosto de los años 2017, 2018, 2019 y 2020**. Los periodos de 2018 y 2020 se definen como '*problemáticos*' pues corresponden con eventos de eutrofización detectados por la CHE. Por contraste, los periodos de 2017 y 2019 se consideran '*no problemáticos*', al no registrarse alertas de eutrofización en esas fechas.

La finalidad de esta iteración es determinar si alguna banda espectral o el NDVI exhiben un comportamiento similar entre periodos de la misma naturaleza. Esto es, para una banda dada, que los periodos con problemas de eutrofización sean similares entre sí y distintos a los periodos sin problemas. Una correlación tal se consideraría un fuerte indicio de que la banda es un indicador prometedor.


Desarrollo:

Se procede a la graficación de las curvas de reflectancia para cada banda y para el NDVI. Siguiendo la metodología descrita al comienzo de A.3, se genera una gráfica individual para cada banda, en la cual se superponen las cuatro curvas correspondientes a los cuatro periodos de estudio. Para cuantificar la similitud entre estas curvas, se calculan las tablas de coeficientes de correlación de Pearson, tal y como se justifica en A.3.

El criterio de éxito para la identificación de un indicador se basa en que los coeficientes de correlación sean altos entre los años problemáticos (2018 y 2020) y entre los años no problemáticos (2017 y 2019), siendo al mismo tiempo bajos entre las combinaciones de años problemáticos y no problemáticos. Cabe destacar, además, que a partir de esta iteración se emplea la interpolación spline de **orden 3** para las curvas, con el fin de incrementar la precisión y extraer conclusiones más reveladoras en pruebas subsiguientes, dado que hay menos curvas por gráfica. Las gráficas (figura A.2) y las tablas de correlación (figura A.3) resultantes están en los anexos.



(a)



(c)

Coefficientes de correlación para la banda B03

	2017	2018	2019	2020
2017	1	0.3480	0.6271	0.4762
2018	0.3480	1	0.6651	0.7566
2019	0.6271	0.6651	1	0.7541
2020	0.4762	0.7566	0.7541	1

(b)

Coefficientes de correlación para la banda B05

	2017	2018	2019	2020
2017	1	0.6155	0.5606	0.5359
2018	0.6155	1	0.6343	0.7214
2019	0.5606	0.6343	1	0.7506
2020	0.5359	0.7214	0.7506	1

(d)

Figura 2.2.: Reflectancias y correlaciones de las bandas 3 y 5 durante los periodos de 2017, 2018, 2019 y 2020

Resultados:

El análisis visual de las gráficas no revela una banda espectral que se distinga claramente como un indicador prometedor. Contrariamente a las expectativas, se observa una mayor similitud en el comportamiento de las curvas entre los años 2017 y 2018, y entre 2019 y 2020. Y las tablas de coeficientes de correlación tampoco proporcionan resultados más concluyentes.

Aunque para bandas específicas, como la 3 o la 5 (véase 2.2, las correlaciones esperadas como elevadas sí lo son, las correlaciones que deberían ser bajas también presentan valores similares. Por consiguiente, se concluye que no se ha identificado un indicador robusto bajo este enfoque, lo que justifica la realización de pruebas adicionales.

2.2.5. Iteración 5

Objetivos:

El propósito de esta iteración es investigar la viabilidad de la temperatura del embalse como un indicador de eutrofización. Para el embalse de El Val se dispone de un registro exhaustivo de temperaturas desde 2016 hasta 2023 facilitado por la CHE (véase el archivo 'medidas_elVal' en la carpeta 'raw_datasets' del repositorio de este proyecto¹²).

La metodología empleada es análoga a la de la iteración anterior, analizando el progreso de la temperatura entre el 4 de mayo y el 4 de agosto en cuatro años distintos: dos 'problemáticos' (2018 y 2020) y dos 'no problemáticos' (2019 y 2022). Cabe destacar que de esta iteración en adelante se selecciona 2022 en lugar de 2017 como año no problemático para asegurar una mayor disponibilidad de imágenes satelitales, dada la fecha de lanzamiento de Sentinel-2B a mediados de 2017. Se evalúan los siguientes posibles indicadores de eutrofización basados en la temperatura diaria: la temperatura media, la temperatura mínima, la temperatura máxima y el ratio entre la temperatura máxima y la mínima (T_{max}^a / T_{min}^a).

Desarrollo:

Para cada uno de los indicadores de temperatura seleccionados, se normalizan los valores al intervalo $[0, 1]$ con el fin de permitir una comparación equitativa. Posteriormente, se generan gráficas que muestran la evolución de cada indicador a lo largo de los cuatro periodos de estudio. Adicionalmente, para cuantificar las similitudes entre las curvas de los distintos años, se calculan y se presentan las tablas de correlaciones correspondientes, siguiendo el mismo enfoque metodológico de las iteraciones previas. Las gráficas resultantes se presentan en la figura A.4 y las tablas de correlación en la figura A.5, ambas en los anexos.

¹²<https://github.com/ppmico/colabo-iza-thesis>

Resultados:

Las gráficas de temperatura obtenidas presentan una oscilación considerable y aportan poca información concluyente respecto a la identificación de patrones asociados a la eutrofización. El único patrón consistente, con la excepción del ratio entre temperaturas mínima y máxima, es el aumento predecible de la temperatura a medida que se aproxima el mes de agosto.




Figura 2.3.: Progreso del ratio T_{max}^a/T_{min}^a durante los 4 periodos de interés, y correlaciones entre dichos periodos

Concretamente en la gráfica del ratio entre temperatura máxima y mínima (ver 2.3), se observan ciertas similitudes entre pares de años, concretamente entre 2018 y 2019, y entre 2020 y 2022, donde las curvas de los primeros presentan una menor oscilación. Sin embargo, estas similitudes carecen de relevancia para el objetivo de la investigación, ya que se espera que sean los años problemáticos (2018 y 2020) los que muestren similitud entre sí y se diferencien de los años no problemáticos (2019 y 2022).

Las tablas de correlación tampoco revelan patrones prometedores de similitud y diferencia. Si bien los años 2018 y 2020 exhiben una correlación considerable para todos los indicadores excepto el ratio, la correlación entre los años no problemáticos (2019 y 2022) no es significativamente superior a la observada entre otras combinaciones de años (problemáticos y no problemáticos). En consecuencia, se concluye que la temperatura, en las formas analizadas, no aporta una utilidad significativa como indicador de eutrofización para los propósitos de este estudio.

2.2.6. Iteración 6

Objetivos:

Con base en el asesoramiento experto del Dr. Mario Esteban y los resultados previos presentados en la Iteración 4, se han identificado las bandas espectrales 9 y 11 como

2. Trabajo desarrollado

las más prometedoras para indicar la eutrofización, debido a su comportamiento diferencial en periodos con y sin problemas.

El objetivo de esta iteración es investigar si una combinación lineal de estas dos bandas puede ofrecer una mayor capacidad discriminadora que cada una por separado. Para ello, se evalúa la viabilidad de las combinaciones $B_{09} * B_{11}$ y B_{09} / B_{11} como indicadores de eutrofización.


Desarrollo:

Se procede a la creación de las curvas para las combinaciones $B_{09} * B_{11}$ y B_{09} / B_{11} siguiendo la metodología descrita en A.3. Al igual que en las iteraciones anteriores, el análisis se centra en el periodo comprendido entre el 4 de mayo y el 4 de agosto de dos años problemáticos (2018 y 2020) y dos años no problemáticos (2019 y 2022), y se obtienen las gráficas del progreso de las reflectancias de ambas combinaciones de bandas y las tablas de correlación correspondientes.

Como en iteraciones anteriores, un indicador se considera prometedor si las curvas de los años problemáticos presentan una alta correlación entre sí, lo mismo ocurre con las curvas de los años no problemáticos, y, a su vez, si las correlaciones entre los periodos problemáticos y no problemáticos son significativamente bajas. Las gráficas y tablas de correlación obtenidas se presentan en las figuras A.6 y A.7 respectivamente.

Resultados:

Los resultados obtenidos en esta iteración son notablemente más prometedores en comparación con las pruebas anteriores. Las gráficas A.6 muestran que las curvas correspondientes a los años problemáticos (2018 y 2020) exhiben patrones de crecimiento y decrecimiento altamente similares entre sí, con la presencia de picos pronunciados a principios de julio en ambos casos, coincidiendo con las detecciones de eventos de eutrofización por parte de la CHE.



Coefficientes de correlación para la combinación $B_{09} * B_{11}$

	2018	2019	2020	2022
2018	1	0.2830	0.6489	0.2857
2019	0.2830	1	0.2315	0.5498
2020	0.6489	0.2315	1	0.1971
2022	0.2857	0.5498	0.1971	1

(b)

Figura 2.4.: Curvas de las reflectancias y correspondientes correlaciones de la combinación $B_{09} * B_{11}$

El examen de las tablas de correlación (figura A.7) refuerza la conclusión de que estas combinaciones pueden ser indicadores eficaces. Particularmente para la combinación $B_{09} * B_{11}$ (ver 2.4), las correlaciones entre los años 2018 y 2020, y entre 2019 y 2022, son notablemente superiores, excediendo el valor de 0.5. En contraste, las correlaciones entre los años problemáticos y no problemáticos no superan el valor de 0.3, lo que indica una clara diferenciación entre ambos tipos de periodos.

En conclusión, y a la espera de la realización de pruebas adicionales que confirmen su robustez, la combinación $B_{09} * B_{11}$ se selecciona como el indicador de eutrofización principal para el entrenamiento de los modelos de aprendizaje automático en las fases subsiguientes de este trabajo.

2.2.7. Iteración 7

Objetivos:

A pesar de que las pruebas en la Iteración 5 sugieren que la temperatura en el embalse no constituye un indicador unívoco de eutrofización, se plantea la hipótesis de que su combinación con las medidas de reflectancia podría mejorar los indicadores cuya utilidad ya ha sido probada en la iteración anterior. Esta iteración tiene como objetivo evaluar la capacidad predictiva de emplear conjuntamente las ya estudiadas combinaciones de las bandas espectrales 9 y 11 con la temperatura mínima, máxima, media y el ratio entre temperatura máxima y mínima (T_{max}^a / T_{min}^a). El criterio para la selección de un indicador mejorado se mantiene: las curvas de los periodos problemáticos (2018 y 2020) deben ser similares entre sí y claramente diferenciables de las curvas de los periodos no problemáticos (2019 y 2022), las cuales también deben mostrar similitud interna.

Desarrollo:


Para todas las pruebas de esta iteración, se emplean los datos comprendidos entre el 4 de mayo y el 4 de agosto de los años 2018, 2019, 2020 y 2022. Inicialmente, se normalizan al intervalo $[0, 1]$ los valores de temperatura y de las combinaciones de bandas ($B_{09} * B_{11}$ y B_{09} / B_{11}). Primeramente se grafican las curvas de la temperatura media y el ratio T_{max}^a / T_{min}^a en la misma gráfica que las combinaciones de bandas de interés (figuras A.8 y A.12), pero la densidad de curvas en la gráfica genera una representación visual compleja y desordenada, lo que complica la extracción de conclusiones claras. Por ello, se separan las mismas curvas en una gráfica por año (figuras A.9 y A.13).

A continuación, tras el fracaso de las pruebas anteriores se procede graficar **el producto** de las combinaciones de bandas de interés con la temperatura media y con el ratio T_{max}^a / T_{min}^a . Se obtienen las gráficas (figuras A.10 y A.14) y los respectivos coeficientes de correlación (figuras A.11 y A.15).

Llegado este punto dado el rendimiento inferior de la combinación B_{09} / B_{11} en las iteraciones previas, se descarta esta combinación para las pruebas subsiguientes, centrándose el análisis exclusivamente en $B_{09} * B_{11}$. Se grafica la evolución de la temperatura mínima y máxima junto con $B_{09} * B_{11}$ (figuras A.16 y A.17). Y finalmente, se calcula y grafica el producto de las temperaturas mínima y máxima con la reflectancia $B_{09} * B_{11}$ (ver figura A.18), generando sus respectivas tablas de correlación (figura A.19).

Resultados:

Las pruebas iniciales con la temperatura media y el ratio entre temperaturas máxima y mínima no revelan una similitud aparente ni correlaciones significativas con las combinaciones de bandas. Las gráficas conjuntas y separadas muestran poca o nula correspondencia entre los patrones de temperatura y los de reflectancia. Y el graficado de productos entre estas variables de temperatura y las combinaciones de bandas ($B_{09} * B_{11}$ y B_{09}/B_{11}) tampoco produce los patrones esperados de similitud dentro de los periodos problemáticos/no problemáticos ni de diferenciación entre ellos.



Corr. matrix (coef de Pearson) de $B_{09} * B_{11} * T^a_{max}$:

	2018	2019	2020	2022
2018	1	0.4915	0.6845	0.1169
2019	0.4915	1	0.4506	0.3105
2020	0.6845	0.4506	1	-0.0787
2022	0.1169	0.3105	-0.0787	1

Figura 2.5.: Curvas y correlaciones entre las mismas del producto del la T^a máxima con la reflectancia de $B_{09} * B_{11}$

El análisis de las temperaturas mínima y máxima con la combinación $B_{09} * B_{11}$ también muestra una baja similitud en sus evoluciones individuales. Al calcular el producto de la reflectancia de la combinación $B_{09} * B_{11}$ con las temperaturas máximas y mínimas, se observan resultados moderadamente mejores con la temperatura máxima (ver figura 2.5), evidenciando mayores similitudes dentro de periodos de la misma naturaleza y mayores diferencias entre periodos problemáticos y no problemáticos. Sin embargo, este mejoramiento no es concluyente, ya que el periodo problemático de 2019 muestra una correlación más intensa con el periodo no problemático de 2020 que con el periodo de su misma naturaleza en 2022.

Por consiguiente, se concluye que ni la temperatura mínima, ni la máxima, ni la media, ni su ratio, ya sea de forma individual o en combinación lineal con el indicador $B_{09} * B_{11}$, aportan una mejora significativa en la capacidad predictiva para la detección de la eutrofización. El indicador $B_{09} * B_{11}$ se mantiene como el más prometedor.

2.2.8. Iteración 8

Objetivos:

El objetivo principal de esta iteración es iniciar la **construcción del corpus de datos necesario para el entrenamiento** de los modelos de aprendizaje automático. Este corpus debe integrar el valor de la combinación de bandas espectrales seleccionada ($B_{09} * B_{11}$) con concentraciones de cianobacterias, clasificadas según los niveles de alerta de la OMS (ver figura 1.1). Para ello se busca identificar conjuntos de datos

públicos, que contengan mediciones de cianobacterias con sus respectivas fechas y localizaciones geográficas para poder solicitar y procesar la correspondiente información satelital.

Desarrollo:

Para cada medición de cianobacterias, se asocia la lectura satelital más cercana en el tiempo, ya que las lecturas satelitales para cada posible localización en la que se realiza una medición de cianobacterias tienen una frecuencia de 5 días, por lo que ambas lecturas pueden no coincidir. Tomada esta decisión, para ponderar la relevancia de esta asociación, se introduce un atributo '*peso*', que cuantifica la diferencia temporal en días. La intención es que este atributo permita al modelo ajustar la importancia de la lectura satelital en función de su desfase respecto a la medición de cianobacterias.

Se realiza una investigación exhaustiva de conjuntos de datos públicos con mediciones de concentraciones de cianobacterias. Se identifican cuatro conjuntos relevantes, denominados **Dataset 1**¹³ (con datos de 20 embalses en EE. UU. hasta 2018), **Dataset 2**¹⁴ (con ubicaciones variadas y escasas muestras por localización), **Dataset 3**, (Xue et al., 2024, mediciones del lago Taihu en China, escasas y no específicas de cianobacterias) y **Dataset 4**, (Gupta et al., 2024, con 13.701 mediciones desde 2017 y coordenadas precisas). Se prioriza el preprocesamiento de Dataset 1 y Dataset 4 por su mayor viabilidad.

Se comienza durante esta iteración el procesamiento del Dataset 1. Para la obtención del valor del indicador $B_{09} * B_{11}$ para cada embalse y fecha de medición de cianobacterias se requiere de una solicitud a la API de Sentinel Hub. Estas solicitudes exigen el conocimiento de la geometría y coordenadas geográficas del área de interés y del embalse en sí¹⁵, información que se encapsula en la clase `ReservoirShape` con los atributos `geometry`, `size`, `bbox` y `dataMask`. Cabe mencionar que el atributo `dataMask` no es necesario para la solicitud de la información satelital del embalse pero igualmente es necesario y se almacena en los objetos `ReservoirShape` por conveniencia.

Para facilitar el acceso a dicha información al realizar las solicitudes, en el notebook `geometrias_embalses_dataset1` disponible en el repositorio de este proyecto¹⁶, se crea, puebla y serializa un diccionario con la forma `{'id del embalse': ReservoirShape}` llamado `reservoir_shapes`. Para poblar este diccionario se necesita obtener el valor concreto de los atributos de cada objeto de la clase `ReservoirShape` correspondiente a cada uno de los 20 pantanos. Este poblamiento implica dos pasos:

1. **Obtención de la información geográfica y geométrica del embalse:** En la plataforma colaborativa `OpenStreetBrowser`¹⁷, están disponibles para su

¹³Más acerca del Dataset 1 en la página catalog.data.gov

¹⁴Dataset obtenido de [la página de la EPA](https://www.epa.gov)

¹⁵Más información en la [documentación](#)

¹⁶<https://github.com/ppmico/colabo-iza-thesis>

¹⁷<https://www.openstreetbrowser.org/>

descarga los archivos de tipo geojson que describen cada uno de los 20 pantanos de los que hay datos en el Dataset 1. Se adquieren manualmente los atributos *geometry*, *size* y *bbox* de cada embalse manualmente empleando dichos archivos. El valor de estos atributos es imprescindible para llevar acabo el siguiente paso, pues este implica una solicitud a la API de SentinelHub.

2. **Obtención de la máscara de datos más representativa:** Mediante una solicitud a la API de Sentinel Hub, se identifica la fecha, dentro de una ventana de 10 días, en la que la tesela satelital capturada sobre el Área de Interés (AOI) del embalse en cuestión abarca la máxima superficie, optimizando así el área del embalse considerada. Esto se debe a que, si bien algún punto del área de un embalse es fotografiado cada 5 días la frecuencia de revisita del satélite para exactamente la misma tesela y ángulo de visión es de 10 días.

Resultados:

La investigación de conjuntos de datos culmina con la identificación y priorización del **Dataset 1** y el **Dataset 4** como los más adecuados para la construcción del corpus de entrenamiento, quedando los otros dos como opciones auxiliares en el caso de que el 1 y el 4 resulten inservibles. Se establece una metodología para la asociación de mediciones *in situ* con lecturas satelitales, incluyendo la implementación del atributo '*peso*' para cuantificar la relevancia temporal.

Para el Dataset 1, se ha completado exitosamente el proceso de obtención de la información geográfica necesaria. Se ha creado, poblado y serializado el diccionario `reservoir.shapes` con los atributos relativos a la información geométrica y satelital (*geometry*, *size*, *bbox*) y la máscara de datos más representativa para cada uno de los 20 embalses. Este proceso asegura que las futuras solicitudes a la API de Sentinel Hub y el posterior procesamiento de la información solicitada se realicen con la geometría precisa y la máxima cobertura de datos disponible. La preparación de esta información fundamental sienta las bases para la posterior extracción de los valores del indicador $B_{09} * B_{11}$ para este conjunto de datos.

2.2.9. Iteración 9

Objetivos:

El objetivo primordial de esta iteración es la creación de un conjunto de datos con las características definidas en la iteración anterior, en el que cada muestra incorpora:

- La **etiqueta a predecir:** La concentración de cianobacterias medida, categorizada según las clases definidas por la OMS ya mencionadas, más una clase adicional para concentraciones superiores a 100.000 células/L ó 10 mm³/L.
- El **atributo 'promedio'**, que representa el promedio de los valores de los píxeles de la imagen satelital correspondiente a la combinación de bandas

espectrales $B_{09} * B_{11}$ tomada en la fecha más próxima a la medida de concentración de cianobacterias.

- El **atributo 'peso'**, que cuantifica la diferencia en días entre la medición de cianobacterias y la lectura satelital más cercana.

Desarrollo:

La construcción del conjunto de entrenamiento se realiza en el *notebook* 'primeras_pruebas.Dataset1y4'. El proceso implica la iteración sobre las mediciones de cianobacterias del Dataset 1 y la asociación de cada una con la lectura satelital más cercana en el tiempo para obtener el valor del indicador $B_{09} * B_{11}$. Tras la ejecución del bucle de generación de muestras y el descarte de aquellas afectadas por nubes o ausencia de agua, se obtienen **537 muestras válidas** a partir de las 1510 mediciones de concentración de cianobacterias disponibles en el dataset original.

No obstante, un análisis pormenorizado del Dataset 1 revela una problemática crítica: la presencia de múltiples mediciones de cianobacterias para un mismo embalse en la misma fecha, las cuales corresponden a diferentes profundidades (superficie, 5m, 10m, 20m). Estas mediciones exhiben una alta variabilidad en la concentración de cianobacterias, incluso para la misma jornada y embalse, como ilustra el extracto de datos para el lago Buckhorn en la figura 2.6.

C	D	E	F	G	H	I
reserv	year	month	day	depth	density_cells/ml	FinalT
BHR	2018	9	20	20	479,2255932	Cyanobac
BHR	2018	9	20	20	23918,40117	Cyanobac
BHR	2018	9	20	20	303579,7072	Cyanobac
BHR	2018	9	20	20	218945,3646	Cyanobac
BHR	2018	9	20	20	5519,63104	Cyanobac
BHR	2018	9	20	20	151789,8536	Cyanobac
BHR	2018	9	20	5	372,7310169	Cyanobac
BHR	2018	9	20	0	1677,289576	Cyanobac
BHR	2018	9	20	5	10349,3082	Cyanobac
BHR	2018	9	20	0	14054,61607	Cyanobac
BHR	2018	9	20	10	19932,00098	Cyanobac
BHR	2018	9	20	0	61073,6953	Cyanobac
BHR	2018	9	20	0	66951,0802	Cyanobac
BHR	2018	9	20	5	76278,2345	Cyanobac
BHR	2018	9	20	0	82283,38864	Cyanobac
BHR	2018	9	20	5	85860,92728	Cyanobac
BHR	2018	9	20	10	88160,77355	Cyanobac
BHR	2018	9	20	10	92760,46608	Cyanobac
BHR	2018	9	20	5	126874,8524	Cyanobac
BHR	2018	9	20	10	142207,1608	Cyanobac
BHR	2018	9	20	0	162778,008	Cyanobac
BHR	2018	9	20	5	230751,2421	Cyanobac
BHR	2018	9	20	10	349959,9402	Cyanobac

Figura 2.6.: Ejemplo de muestras en un mismo día y pantano para el Dataset 1

Resultados:

Inicialmente, se logra generar un conjunto de 537 muestras para el entrenamiento del modelo. Sin embargo, el descubrimiento de la heterogeneidad en las mediciones de cianobacterias del Dataset 1 para una misma fecha y embalse invalida este procedimiento de construcción del conjunto de entrenamiento. La coexistencia de múltiples etiquetas de concentración con un único valor de reflectancia satelital, que no discrimina por profundidad, impide la creación de un corpus coherente y significativo para el aprendizaje del modelo. La figura 2.6 evidencia esta inconsistencia.

Por consiguiente, se concluye que el Dataset 1 no es apto para el propósito de entrenar un modelo de detección temprana de eutrofización. Se procede a su descarte para este fin. No obstante, el trabajo de preprocesamiento y la experiencia adquirida en el manejo de este conjunto de datos serán de utilidad en futuras iteraciones.

2.2.10. Iteración 10

Objetivo:

El objetivo central de esta iteración es la creación del conjunto de datos de entrenamiento empleando las muestras del Dataset 4. Este proceso implica la adquisición precisa de la información geográfica de cada cuerpo de agua asociado a las mediciones de cianobacterias, la gestión de las posibles inconsistencias en las geometrías obtenidas de *OpenStreetMap* (OSM) y la generación de máscaras de datos satelitales específicas para cada localización. Finalmente, se busca integrar estas lecturas satelitales con los datos de concentración de cianobacterias para conformar el dataset final.

Desarrollo:

El preprocesamiento del *Dataset 4* se estructura en las siguientes fases:

1. **Adquisición de la geometría de los cuerpos de agua:** Cada medición de concentración de cianobacterias en este conjunto de datos incluye la latitud y longitud de la ubicación del muestreo, que es potencialmente única para cada medición. Esta información se utiliza para obtener la geometría del cuerpo de agua correspondiente (embalse, lago, etc.) mediante una solicitud a la API de OpenStreetMap (OSM)¹⁸. Esta solicitud se encapsula en la función `get_lake_reservoir_geometry`, la cual recibe las coordenadas de la medición y la distancia del muestreo al cuerpo de agua. Si existe en la base de datos de OSM, la función devuelve la información geométrica y geográfica necesaria para poblar los atributos `geometry`, `size` y `bbox` de un objeto de la clase `ReservoirShape`.

¹⁸<https://wiki.openstreetmap.org/wiki/API>

Inicialmente, la aplicación de esta función para la instanciación de objetos `ReservoirShape` revela un porcentaje elevado de fallos, donde no se encontraba un cuerpo de agua correspondiente en la base de datos de OSM. Adicionalmente, una proporción significativa de las geometrías recuperadas presentaba inconsistencias, como auto-intersecciones o discontinuidades. Para corregir estas imperfecciones, se emplea el método `buffer`¹⁹ de la biblioteca `shapely`, y para un gran número de polígonos este método resuelve las irregularidades devolviendo el polígono arreglado (ver figura 2.7). En los casos donde este método resulta en un objeto `MultiPolygon` (lo que se trata de un comportamiento regular, dado que para arreglar algunas irregularidades es necesario dividir el polígono original), se asume que la forma más representativa del cuerpo de agua es el polígono de mayor complejidad (mayor número de vértices), dada la tendencia (observada experimentalmente) a ser el más descriptivo y de mayor extensión.




Figura 2.7.: Ejemplo de geometría obtenida de OSM antes y después de usar el método `buffer`

2. Generación de máscaras de datos y definición de objetos `ReservoirShape`:

Una vez obtenida la información geométrica de cada cuerpo de agua, se procede a la obtención de sus máscaras de datos. Este proceso es análogo al empleado con el *Dataset 1*: se efectúa una solicitud a la API de Sentinel Hub para identificar, dentro de un ciclo de 10 días, la fecha en que la tesela satelital capturada sobre el Área de Interés (AOI) abarca la máxima superficie del cuerpo de agua. Esta fecha se utiliza para la solicitud final de la máscara de datos. Este proceso culmina con la asignación de valores al atributo `dataMask` del objeto `ReservoirShape` correspondiente a cada lectura de cianobacterias, permitiendo así disponer de objetos correctamente definidos para realizar las solicitudes a la API de Sentinel Hub con las que completar el conjunto de datos de entrenamiento.

3. Creación del Dataset Final:

Con cada instancia de la clase `ReservoirShape` correctamente inicializada, se procede a efectuar las solicitudes a la API de Sentinel Hub para obtener las lecturas satelitales correspondientes a cada medición. El resultado de estas solicitudes completa el conjunto de datos final,

¹⁹Más información en la [documentación](#)

almacenado en un objeto `DataFrame` que contiene como columnas los campos definidos al comienzo de la Iteración 9 y, en teoría, una fila por cada medición presente en el *Dataset 4*.

Resultados:

A pesar de que el *Dataset 4* contenía inicialmente más de 13.000 mediciones de concentraciones de cianobacterias, el proceso de adquisición de geometrías válidas reveló una limitación significativa: solo fue posible obtener algo más de 600 áreas de cuerpos de agua con geometrías consistentes a través de la API de OSM. Esta problemática podría atribuirse a la naturaleza colaborativa de la información geográfica en OSM, donde muchos cuerpos de agua pueden estar mal etiquetados. Y también influye el hecho de que muchas de las mediciones de cianobacterias en el *Dataset 4* han sido tomadas en ríos o cuerpos de agua minúsculos, no considerados para esta investigación dado que no pueden albergar floraciones cianobacterianas detectables. De las muestras restantes, un número considerable de datos no superó los filtros de calidad (número de píxeles con agua y sin nubes), lo cual ya había sido observado en pruebas anteriores.

En consecuencia, la disponibilidad final de datos procesables para el análisis se ha visto drásticamente reducida. Este hecho subraya la **complejidad inherente a la adquisición y validación de información geográfica de fuentes externas**, y reafirma la importancia de considerar el **elevado porcentaje de datos descartados debido a la presencia de nubes o la ausencia de agua** en los cuerpos de agua en el momento de la lectura satelital.

2.2.11. Iteración 11

Objetivos:

El objetivo principal de esta iteración es evaluar un abanico de modelos de inteligencia artificial y técnicas de aprendizaje automático ya existentes en el contexto de la detección de concentraciones elevadas de cianobacterias. Encontrado ya un indicador sensible a los periodos de floraciones cianobacterianas (la combinación de bandas espectrales $B_{09} * B_{11}$) se aborda el problema como una tarea de clasificación supervisada tal que, dado el valor de dicho indicador, el propósito del modelo es clasificar correctamente el estado trófico de un embalse. Se definen dos formulaciones del problema: una de clasificación multiclase, basada en los niveles de alerta de la OMS, y otra binaria, enfocada en la determinación de un estado de alerta.

Desarrollo:

Para abordar el problema de clasificación supervisada, se seleccionan y preparan, con ayuda del Dr. Mario Mesuaza, experto en el campo, las siguientes técnicas de aprendizaje automático para su evaluación:

- **Regresión Logística:** Se establece como un modelo de línea base para determinar la existencia de una relación lineal subyacente y servir como referencia de rendimiento.
- **Bosques Aleatorios:** Elegidos por su interpretabilidad, robustez y menor tendencia al sobreajuste, característica esta última valiosa dada la dimensión reducida del conjunto de entrenamiento.
- **Modelos de Boosting (*AdaBoost*, *GradientBoosting*, *LightGBM*, *XGBoost*):** Se consideran por su capacidad para generalizar y resolver problemas no lineales, lo cual es crucial dada la posible no linealidad y el ruido inherente a los datos de teledetección.
- **Máquinas de Vectores de Soporte (SVM):** Se exploran para capturar posibles relaciones no lineales entre las lecturas satelitales y la concentración de cianobacterias, esperando un rendimiento superior al de la regresión logística.
- **Red Neuronal Simple:** Dada la naturaleza y cantidad de datos, se opta por configuraciones sencillas de *MultiLayer Perceptron* (MLP), adecuadas para problemas de clasificación estándar, aunque se reconoce que la cantidad limitada de datos podría ser una limitación.

El conjunto de datos obtenido a partir del *Dataset 4* se utiliza para el entrenamiento, mientras que la validación de los modelos se realiza empleando los datos históricos del embalse de El Val, proporcionados por la CHE (detallados en [A.1](#)). Primeramente se crean las estructuras de datos pertinentes para la clasificación multiclase, definiendo cinco clases objetivo (los cuatro niveles de alerta de la OMS más una clase adicional para concentraciones superiores a 100.000 células/L o 10 mm³/L). El desbalanceo de la clase 0 se aborda mediante un submuestreo aleatorio, manteniendo un número de muestras equivalente al de la siguiente clase más frecuente.

Posteriormente, se configura el segundo problema de clasificación, de naturaleza **binaria**, agrupando las clases objetivo del problema multiclase en 'no alertar' (niveles de alerta 0 y 1) y 'alertar' (clases restantes). Este enfoque binario se considera aborda la principal utilidad para la que se desea desarrollar un modelo: funcionar como un sistema de alerta, lo cual requiere una respuesta clara y dicotómica: ¿se debe actuar o no? Finalmente, se procede al entrenamiento y validación de todos los modelos en el *notebook* *validacionConElVal*. Para la red neuronal se entrena únicamente para el problema binario y se comienza directamente con la optimización de hiperparámetros, a diferencia de los otros modelos que emplean valores por defecto en esta primera aproximación.

Resultados:

Los resultados de los modelos sin optimizar se recogen en la figura [2.8](#). Para la clasificación multiclase, la limitada disponibilidad de datos por clase impide que cualquier modelo alcance prestaciones aceptables en la determinación precisa del nivel de alerta específico. Sin embargo, para el problema en su versión binaria, gran parte de los modelos arrojan resultados satisfactorios, alcanzando precisiones superiores al 70 %.

2. Trabajo desarrollado

Regresión logística	Random Forests	GradientBoost	AdaBoost
----- Clasificación multiclase ----- Accuracy: 0.14285714285714285 precision recall f1-score support 0 0.00 0.00 0.00 0 1 0.00 0.00 0.00 2 2 0.00 0.00 0.00 2 3 0.50 0.33 0.40 3 accuracy 0.14 7 macro avg 0.12 0.08 0.10 7 weighted avg 0.21 0.14 0.17 7 ----- Clasificación binaria ----- Accuracy: 0.5714285714285714 precision recall f1-score support 0 0.40 1.00 0.57 2 1 1.00 0.40 0.57 5 accuracy 0.57 7 macro avg 0.70 0.70 0.57 7 weighted avg 0.83 0.57 0.57 7	----- Clasificación multiclase ----- Accuracy: 0.14285714285714285 precision recall f1-score support 0 0.00 0.00 0.00 0 1 0.00 0.00 0.00 2 2 0.00 0.00 0.00 2 3 0.50 0.33 0.40 3 4 0.00 0.00 0.00 0 accuracy 0.14 7 macro avg 0.10 0.07 0.08 7 weighted avg 0.23 0.14 0.17 7 ----- Clasificación binaria ----- Accuracy: 0.5714285714285714 precision recall f1-score support 0 0.00 0.00 0.00 2 1 0.07 0.00 0.03 5 accuracy 0.57 7 macro avg 0.33 0.40 0.36 7 weighted avg 0.48 0.57 0.52 7	----- Clasificación multiclase ----- Accuracy: 0.14285714285714285 precision recall f1-score support 0 0.00 0.00 0.00 0 1 0.00 0.00 0.00 2 2 0.00 0.00 0.00 2 3 1.00 0.33 0.50 3 4 0.00 0.00 0.00 0 accuracy 0.14 7 macro avg 0.20 0.07 0.10 7 weighted avg 0.43 0.14 0.21 7 ----- Clasificación binaria ----- Accuracy: 0.7142857142857143 precision recall f1-score support 0 0.50 0.50 0.50 2 1 0.00 0.00 0.00 5 accuracy 0.71 7 macro avg 0.65 0.65 0.65 7 weighted avg 0.71 0.71 0.71 7	----- Clasificación multiclase ----- Accuracy: 0.14285714285714285 precision recall f1-score support 0 0.00 0.00 0.00 0 1 1.00 0.50 0.67 2 2 0.00 0.00 0.00 2 3 0.00 0.00 0.00 3 4 0.00 0.00 0.00 0 accuracy 0.14 7 macro avg 0.28 0.10 0.13 7 weighted avg 0.29 0.14 0.19 7 ----- Clasificación binaria ----- Accuracy: 0.7142857142857143 precision recall f1-score support 0 0.50 0.50 0.50 2 1 0.00 0.00 0.00 5 accuracy 0.71 7 macro avg 0.65 0.65 0.65 7 weighted avg 0.71 0.71 0.71 7
XGBoost	SVM	LightGBM	Red neuronal simple
----- Clasificación multiclase ----- Accuracy: 0.14285714285714285 precision recall f1-score support 0 0.00 0.00 0.00 0 1 1.00 0.50 0.67 2 2 0.00 0.00 0.00 2 3 0.00 0.00 0.00 3 4 0.00 0.00 0.00 0 accuracy 0.14 7 macro avg 0.20 0.10 0.13 7 weighted avg 0.29 0.14 0.13 7 ----- Clasificación binaria ----- Accuracy: 0.7142857142857143 precision recall f1-score support 0 0.50 0.50 0.50 2 1 0.00 0.00 0.00 5 accuracy 0.65 0.65 0.65 7 macro avg 0.71 0.71 0.71 7	----- Clasificación multiclase ----- Accuracy: 0.0 precision recall f1-score support 0 0.00 0.00 0.00 0.0 1 0.00 0.00 0.00 2.0 2 0.00 0.00 0.00 2.0 3 0.00 0.00 0.00 3.0 4 0.00 0.00 0.00 0.0 accuracy 0.00 7.0 macro avg 0.00 0.00 0.00 7.0 weighted avg 0.00 0.00 0.00 7.0 ----- Clasificación binaria ----- Accuracy: 0.2857142857142857 precision recall f1-score support 0 0.20 1.00 0.44 2 1 0.00 0.00 0.00 5 accuracy 0.14 7 macro avg 0.14 0.50 0.22 7 weighted avg 0.08 0.29 0.13 7	----- Clasificación multiclase ----- Accuracy: 0.2857142857142857 precision recall f1-score support 0 0.00 0.00 0.00 0 1 1.00 0.50 0.67 2 2 0.00 0.00 0.00 2 3 1.00 0.33 0.50 3 4 0.00 0.00 0.00 0 accuracy 0.29 7 macro avg 0.48 0.17 0.23 7 weighted avg 0.71 0.29 0.40 7 ----- Clasificación binaria ----- Accuracy: 0.7142857142857143 precision recall f1-score support 0 0.50 0.50 0.50 2 1 0.00 0.00 0.00 5 accuracy 0.71 7 macro avg 0.65 0.65 0.65 7 weighted avg 0.71 0.71 0.71 7	----- Clasificación binaria ----- Accuracy: 0.2857142857142857 precision recall f1-score support 0 0.20 1.00 0.44 2 1 0.00 0.00 0.00 5 accuracy 0.29 7 macro avg 0.14 0.50 0.22 7 weighted avg 0.08 0.29 0.13 7

Figura 2.8.: Resultados de los modelos sin optimizar en la validación con los datos de El Val

A pesar de la limitada representatividad de la validación debido a la escasez de datos del embalse de El Val, se evidencia que las técnicas de *boosting* son las más apropiadas para la problemática, logrando las mejores precisiones. En cuanto a la red neuronal, tras su optimización de hiperparámetros y entrenamiento para el problema binario, se observa cierto sobreajuste. Este fenómeno es coherente con el desbalanceo entre las clases binarias y la reducida dimensión y variabilidad de los datos de entrenamiento, lo que sugiere la necesidad de mejorar la regularización para mitigar dicho sobreajuste.

2.2.12. Iteración 12

Objetivos:

El objetivo principal de esta iteración es optimizar los hiperparámetros de los modelos de aprendizaje automático seleccionados y evaluados en la iteración anterior, con el fin de mejorar su rendimiento a la hora clasificar lecturas satelitales para la detección de la eutrofización. Se busca identificar la estrategia de optimización más efectiva y aplicar esta metodología a todos los modelos candidatos, excluyendo la red neuronal, para potenciar su capacidad de clasificación.

Desarrollo:

Se explora, en primer lugar, la eficacia de diversas estrategias de optimización empleando el modelo de regresión logística debido a su menor complejidad computacional. Las aproximaciones consideradas incluyen:

- **Búsqueda en malla empleando GridSearchCV de *scikit-learn* con *K-Folds* estratificada:** Esta técnica es seleccionada por su idoneidad en conjuntos de datos de reducido tamaño, ya que garantiza la preservación de la representación de las clases en cada partición. Esto es crucial para evitar pliegues sin muestras de alguna clase, lo que podría empeorar la optimización y el rendimiento de los modelos. Además, su integración con la librería *scikit-learn* facilita su implementación dado que muchos de los modelos empleados han sido probados con su implementación de la librería *scikit-learn*.
- **Librería *Hyperopt*:** Se considera por su implementación de algoritmos de optimización bayesiana, que buscan los hiperparámetros óptimos de manera más eficiente que la búsqueda en malla, explorando el espacio de búsqueda de forma inteligente.
- **Librería *Optuna*:** Este *framework* de optimización de hiperparámetros, que también utiliza optimización bayesiana y estrategias de búsqueda avanzada, destaca por su flexibilidad, permitiendo la definición de espacios de búsqueda dinámicos y algoritmos de poda temprana.

Tras una evaluación comparativa, se selecciona la validación cruzada empleando GridSearchCV de la biblioteca *scikit-learn* como la estrategia principal. Esta decisión se justifica en la innecesaria complejidad y eficiencia de las dos opciones restantes, además de por la fácil adopción con los clasificadores y demás funcionalidades de la librería *scikit-learn*. Se implementa una función denominada `grid_search_y_evaluacion` que automatiza el proceso de optimización de hiperparámetros y evaluación de los modelos optimizados. Esta recibe como argumentos un modelo de aprendizaje automático y un diccionario con los rangos de valores de sus hiperparámetros, con el propósito de encontrar la combinación óptima mediante validación cruzada con *K-Folds* para los datos de entrenamiento. Esta función se aplica sistemáticamente para optimizar los hiperparámetros de todos los modelos considerados, a excepción de la red neuronal, cuyos hiperparámetros son optimizados con la librería *keras.tuner*, debido a incompatibilidades con las funcionalidades de la librería *scikit-learn*.

Resultados:

Los resultados obtenidos tras el proceso de optimización de hiperparámetros no revelan mejoras sustanciales en el rendimiento general de los modelos. Si bien durante la validación cruzada, empleando exclusivamente los datos de entrenamiento, se observan en algunos modelos precisiones superiores a las inicialmente alcanzadas con el conjunto de validación, esta mejora no se traslada al rendimiento con el conjunto de validación de El Val.

Al reentrenar y validar estos modelos optimizados utilizando los datos del embalse de El Val, no se consigue, en ningún caso, superar los resultados previos a la optimización. Este fenómeno reitera el desafío inherente a la limitada cantidad de datos disponibles para la validación con las muestras del embalse de El Val. La escasez de muestras implica que cualquier desviación mínima del modelo puede repercutir significativamente en la clasificación, alterando de manera drástica las métricas de rendimiento y dificultando una evaluación concluyente del desempeño

de estos modelos optimizados. Pese a que esto sumado al reducido tamaño del conjunto de entrenamiento elaborado resulta en resultados subóptimos, se considera que ha habido progreso significativo en el objetivo inicial de desarrollar un modelo que pueda servir de base para la construcción de sistemas de alerta de potenciales eventos de eutrofización.

2.3. Aspectos más complejos abordados

Desde el inicio, el **desconocimiento previo sobre todas las herramientas y metodologías necesarias**, propio de un trabajo de investigación como el presente, se manifestó como un desafío recurrente. Un ejemplo claro fue la necesidad de familiarizarse con la librería *shapely* para el tratamiento de geometrías espaciales, cuya relevancia no pudo haberse anticipado antes de abordar uso de APIs de datos satelitales. Esta incertidumbre recurrente, sin embargo, reafirma la validez de la metodología adoptada: Trabajar en un entorno como Google Colab, con una gestión mínima de dependencias, adoptando **una estrategia de mejoras incrementales y graduales en cada iteración, partiendo del trabajo ya realizado en iteraciones anteriores**. Esto junto al registro de los esfuerzos realizados, dudas e información relevante que se llevaba en un documento a modo de *cuaderno de vitácora* personal, facilitó la adaptación continua y la resolución ágil y sin fricción de los problemas que surgieron, demostrando la eficacia de ser flexible lidiando con cuestiones inexploradas como lo es el objeto de este trabajo.

Otro de los retos enfrentados fué **el acceso a la API de SentinelHub** para poder obtener las lecturas satelitales, para lo que es indispensable contar con una suscripción activa. Dada la naturaleza del proyecto se optó por emplear distintas cuentas correo electrónico, empleando una cuenta distinta cada mes para mantener la operatividad de las solicitudes. Para integrar esta gestión de credenciales en el flujo de trabajo, se hizo uso del **sistema de 'secretos' de Google Colab**. Se crearon varios secretos (variables cuyo valor es visible a través de varios *notebooks*) (e.g. '*client_secret*') que almacenan los valores de las variables que deben modificarse en el código cada vez que se cambia de cuenta. Más allá de esto, fue igualmente necesario familiarizarse con la plataforma de Sentinel Hub y aprender a usar su *Dashboard*.

Finalmente, trabajar en un entorno de trabajo en la nube presentó también dificultades a abordar. Por ejemplo, las sesiones en los *notebooks* de Colab se apagaban automáticamente tras periodos de inactividad o ejecuciones prolongadas, impidiendo que procesos de varias horas (como el bucle de creación del conjunto de entrenamiento con el *Dataset 4*, que implicaba solicitudes a dos APIs distintas por cada muestra) pudieran completarse en una única sesión de trabajo.

Para mitigar esta restricción, se hizo uso de **archivos temporales** en los que se guardaba periódicamente el progreso de la ejecución, permitiendo así retomar el trabajo desde el último punto guardado en sesiones anteriores. Por ejemplo, en el bucle de creación del conjunto de entrenamiento con el *Dataset 4*, el progreso se

guardaba cada 100 muestras correctamente procesadas en un archivo intermedio dentro de la carpeta tmp del repositorio. La librería pickle ha tenido, entre otros, el propósito de serializar las estructuras de datos que se estaban poblando en bucles como el mencionado para guardarlas en Google Drive temporalmente hasta que se retomase la ejecución en una sesión de trabajo posterior.

A pesar de las dificultades, cada problema y su resolución se ha traducido en un aprendizaje que muchas veces ha sido útil en fases posteriores del proyecto.

2.4. Magnitud de los esfuerzos realizados

Al inicio de cada iteración, la estimación precisa de las horas de dedicación requeridas para alcanzar los objetivos propuestos era un desafío inherente a la naturaleza exploratoria de un trabajo de investigación. Si bien la planificación inicial contemplaba iteraciones de dos semanas de duración, esta pauta tuvo que ser alterada en más de una ocasión. Diversos imprevistos o la subestimación de la complejidad de ciertas tareas implicaron ajustes en el cronograma, extendiendo o reduciendo la duración de algunas iteraciones para asegurar el cumplimiento de los objetivos establecidos.

En la tabla 2.2 se recogen de manera aproximada las horas dedicadas a cada iteración, así como las fechas de inicio y final entorno a las que comenzaron cada una.

Tabla 2.2.: Horas de dedicación por iteración

Iteración	Fecha de inicio	Fecha final	Horas
Iteración 1	25/06/2024	11/07/2024	25
Iteración 2	12/07/2024	03/08/2024	35
Iteración 3	04/08/2024	30/08/2024	40
Iteración 4	31/08/2024	16/09/2024	25
Iteración 5	17/09/2024	23/09/2024	10
Iteración 6	24/09/2024	10/10/2024	25
Iteración 7	11/10/2024	13/11/2024	50
Iteración 8	14/11/2024	19/12/2024	55
Iteración 9	12/01/2025	20/02/2025	60
Iteración 10	21/02/2025	08/04/2025	65
Iteración 11	09/04/2025	05/05/2025	40
Iteración 12	06/05/2025	28/05/2025	35
Total	25/06/2024	28/05/2025	465

3. Lecciones aprendidas y conclusiones

3.1. Conocimientos adquiridos

La realización de este trabajo ha supuesto, primeramente, una experiencia de aprendizaje: si bien entre los objetivos del grado no se ven reflejados, entre otros he adquirido conocimientos acerca del campo de la teledetección, sobre la interacción constante con diversas APIs, como las de Sentinel Hub y OpenStreetMap, y más. Pero especialmente, el aprendizaje mejor interiorizado ha sido comprender de primera mano las dificultades inherentes e impredecibles que surgen en las fases de recolección y tratamiento de datos en el contexto de la informática, un tema que pese a su relevancia en el mundo actual apenas había conocido hasta ahora.

Además, he aprendido a aplicar conocimientos adquiridos en asignaturas de la carrera como el abanico de técnicas de inteligencia artificial estudiadas en la asignatura de *Aprendizaje automático* de 3º, que han sido utilizadas en las últimas iteraciones del trabajo

Más allá de los conocimientos técnicos, este trabajo me ha aportado una idea de cómo es el trabajo de investigación. He podido apreciar la incertidumbre constante del trabajo en campos inexplorados y la fuente de aprendizaje continuo que ello supone, lo que ha resultado enriquecedor y refrescante ya que hasta ahora durante el grado prácticamente sólo he resuelto problemas preparados.

La dedicación a un mismo proyecto durante un periodo prolongado ha resultado ser particularmente gratificante. De manera casi inconsciente, los problemas sin resolver del TFG ocupaban mis pensamientos en momentos de ocio, lo que, lejos de ser una carga, proporcionaba un sentido de propósito y una dirección clara, un aspecto que ha sido especialmente valorado en el transcurso de este trabajo.

3.2. Ideas futuras

La utilidad del objetivo perseguido en este trabajo es evidente, y demostrar que la inteligencia artificial puede tener aplicaciones prácticas y efectivas en el campo del cuidado del agua destinada al consumo humano es un esfuerzo que merece la pena continuar, incluso una vez completado el TFG. Dada la situación climática actual y la creciente presión sobre los recursos hídricos, optimizar y maximizar los esfuerzos de los expertos dedicados al monitoreo periódico de embalses resulta especialmente importante.

La culminación de este trabajo de fin de grado abre diversas vías para la continuación y expansión de la investigación tratada en el mismo, especialmente en lo relacionado con la disponibilidad de datos y las limitaciones que presenta. Destinando más tiempo, se contempla la búsqueda exhaustiva de más conjuntos de datos de mediciones reales de concentraciones de cianobacterias. La escasez de datos de entrenamiento y validación ha sido el principal obstáculo para alcanzar plenamente los objetivos planteados en este proyecto, y su ampliación puede verse como el siguiente paso con más potencial.

En esta línea, el director del proyecto sugiere una aproximación complementaria que también se contempla: la generación de **datos sintéticos** a partir de los ya obtenidos. Esta estrategia podría ayudar a mitigar el problema de la escasez de datos reales, solventando muchas de las problemáticas que han plagado especialmente las últimas partes de este proyecto.

En cuanto a la parte de aprendizaje automático, futuros esfuerzos en esta investigación estarían destinadas a la explotación de las redes neuronales, que debido a la limitada disponibilidad de datos han tenido resultados subóptimos en este trabajo.

3.3. Conclusiones

El presente trabajo se propuso como objetivo inicial el desarrollo de un modelo predictivo de la eutrofización, concebido como la base para la construcción de sistemas informáticos capaces de generar alertas sobre potenciales problemas en grandes masas de agua. Aunque se reconoce que el rendimiento alcanzado se sitúa en un nivel no alcanza las expectativas iniciales, y hay un amplio margen de mejora, **este objetivo se considera logrado.**

Pese a que se ha conseguido implementar y evaluar varios modelos de aprendizaje automático que cumplen con los requisitos funcionales establecidos, es importante señalar que ninguno de estos modelos destaca de manera excepcional por su rendimiento predictivo; aquellos que logran satisfacer las métricas mínimas lo hacen con un margen muy ajustado. Esta limitación se atribuye principalmente a **la escasa disponibilidad de datos de entrenamiento y validación**, un desafío recurrente a lo largo de las diferentes iteraciones del trabajo.

A pesar de las restricciones impuestas por los datos, se ha logrado identificar que **las técnicas de aprendizaje automático más adecuadas** para abordar este problema específico, bajo las condiciones de datos limitados, **son los algoritmos de *boosting*.** Estos modelos han demostrado ser los que presentan los mejores rendimientos, lo que los posiciona como la opción más prometedora para una posible continuación de esta investigación.

Anexos

Anexo A.

Análisis de la viabilidad del modelo objetivo

El desarrollo de un modelo robusto para la detección de floraciones algales en embalses requiere, como punto de partida, una evaluación exhaustiva de su viabilidad técnica. Este anexo detalla el proceso de selección y preprocesamiento de las fuentes de datos satelitales que constituyen la base de nuestro modelo objetivo.

Se aborda la metodología para la obtención y el filtrado de lecturas satelitales, lo que incluye el tratamiento de píxeles afectados por nubes y la exclusión de áreas sin agua. Adicionalmente, se explora la incorporación de indicadores auxiliares in situ, como la temperatura del agua, y su potencial para complementar la información de teledetección. Finalmente, se presenta un análisis exploratorio y correlacional de las distintas bandas espectrales y sus combinaciones, así como de los registros de temperatura. Esto se hace con el fin de seleccionar los indicadores óptimos que alimentarán los modelos de aprendizaje automático.

A.1. Selección de las fuentes de datos

Se describen los criterios de selección de las diversas fuentes de datos que alimentan el modelo objetivo. Se detalla la obtención de las lecturas satelitales y el proceso de adquisición de otros indicadores auxiliares, si es que fueran necesarios.

A.1.1. Obtención de las lecturas satelitales

La principal entrada para el modelo objetivo son las lecturas satelitales de un embalse, y para la obtención de dichas lecturas, tanto para los datos de entrenamiento como los de validación se han estudiado varias posibilidades de entre las fuentes de datos más comunes: Misión Landsat ¹, Misión Sentinel ² y más fuentes de lecturas satelitales comerciales como Airbus ³.

¹Más información en la [Página del USGS de la misión](#)

²Más información en la [página de la misión de la ESA](#)

³Más información en la [página de Airbus](#)

Se selecciona la misión Sentinel-2 ⁴ debido a la combinación de su política de datos abiertos y sus características técnicas superiores, su resolución espacial principalmente, en comparación con otras misiones de acceso público como Landsat. Concretamente, Sentinel-2 ofrece una mayor resolución temporal (tiempo de revisita de un mismo punto en el globo de 5 días) y una resolución espacial de hasta 10 metros, aspectos cruciales para el monitoreo detallado de cuerpos de agua (véase Tabla 2.1)

Esta misión está compuesta por dos satélites desfasados 180° en su órbita, lo que permite adquirir imágenes de un mismo punto sobre el ecuador cada 5 días. Los satélites de esta misión operan como un sistema multiespectral, capturando la radiancia en diferentes bandas del espectro electromagnético. Las imágenes de una misma banda son creadas con la lectura de los sensores de una misma región del espectro electromagnético. Por ejemplo, el rango espectral de la Banda 2 abarca aproximadamente de 457.5 nm a 522.5 nm de longitud de onda, lo que corresponde a la región del azul en el espectro visible.

La adquisición de los datos de Sentinel-2 se automatiza empleando la interfaz de programación de aplicaciones (API) de Sentinel Hub ⁵. Se desarrolla la función `ApiReqRez`, que gestiona las peticiones a la API, y cuyos parámetros de entrada incluyen la colección de datos solicitada (e.g. la colección de datos del Sentinel-2), una fecha para la que dicho satélite haya tomado imágenes, un 'evalscript' ⁶ para definir las bandas solicitadas y cálculos a realizar en el servidor, y los polígonos vectoriales que definen el área de interés (AOI) del embalse y su perímetro.

La función devuelve un objeto `ndarray` con la forma `[altura, anchura, canales]`, que contiene, para cada 'canal' (banda o índice indicado en el *evalscript*) los valores de los píxeles de la imagen de esa banda o índice.

A.1.2. Obtención de valores de otros indicadores

Además de las variables obtenidas por teledetección, se evalúa la incorporación de variables auxiliares *in situ*. Utilizando datos históricos para el embalse de El Val facilitados por la Confederación Hidrográfica del Ebro (CHE), se determina la efectividad de la temperatura del agua como predictor potencial. Para asegurar la escalabilidad del modelo a otros embalses donde no se dispone de mediciones directas, se analiza la viabilidad de estimar la temperatura del agua a partir de datos de estaciones meteorológicas cercanas. Para ello, se consideran métodos de interpolación espacial como la *Inversa de la Distancia Ponderada* (IDW) o *Kriging*, garantizando así que las fuentes de datos del modelo final sean automáticas o requieran un esfuerzo mínimo de adquisición.

⁴Más información en la [Wiki oficial de la constelación Sentinel-2](#)

⁵[Documentación](#) de la librería para hacer las solicitudes

⁶Más sobre los 'evalscript' en la [documentación](#)

Más adelante, si la temperatura del agua resulta ser efectiva como predictor se contemplará incorporar más variables como la presión atmosférica o nivel de llenado del embalse.

A.2. Preprocesado de las imágenes satelitales

La función `ApiReqRez` descrita en A.1 devuelve imágenes satelitales sin procesar del área dentro del embalse. Para el entrenamiento y evaluación del modelo, sin embargo, se ha decidido emplear sólo aquellos píxeles que correspondan a la lectura de un área que cumpla las siguientes condiciones:

1. Pertenece a los límites del embalse.
2. No presenta nubosidad al momento de la adquisición.
3. Corresponde a una zona con agua: Ya sea por gestión del embalse o por sequía, una región comprendida dentro del embalse puede no albergar agua, y las zonas sin agua (lecho expuesto del embalse) se excluyen del análisis, puesto que las floraciones algales ocurren exclusivamente en la columna de agua.

En lo sucesivo, los píxeles que correspondan a la lectura de un área que cumpla estas tres condiciones se denominan '*píxeles válidos*'.

A.2.1. Filtrado de píxeles con nubes

En teledetección la presencia de nubes puede obstruir la visión del sensor satelital afectando la calidad de los datos obtenidos y limitando su utilidad en el análisis de los cuerpos de agua. Así pues, para asegurar que las imágenes sean representativas y mejorar la precisión de los resultados, es necesario aplicar un '**filtro de nubes**'. En este apartado, se explicará el proceso utilizado para identificar y excluir los píxeles afectados por la nubosidad, propósito para el que se han estudiado varias alternativas:

- **Capas preprocesadas CLM** (*cloud masks*) y **CLP** (*cloud probabilities*)⁷: Estas capas ofrecen para toda lectura de la misión Sentinel 2, respectivamente, una máscara de píxeles afectados por la nubosidad y una máscara con la probabilidad de que cada píxel esté afectado por nubosidad. Aunque estas capas están disponibles a través de la API de Sentinel Hub, se descartan debido a su baja resolución espacial (160 m), la cual es insuficiente para filtrar con precisión las bandas de mayor resolución del sensor MSI (10 m, 20 m y 60 m).

- **L2A scene classification data**^{8 9} A través de la API de Sentinel Hub existe también una capa para la que cada píxel está clasificado en uno de varios tipos,

⁷Más información en la [documentación](#)

⁸Más información en la [wiki de la ESA](#)

⁹Hay una [publicación en el foro de Sentinel Hub](#) al respecto

incluyendo nubes, agua, nieve, etc. Esta clasificación ha sido realizada empleando un algoritmo desarrollado por la agencia espacial europea (ESA). Una opción también prometedora, aunque de base sólo está disponible para Europa. Además, la resolución de esta capa preprocesada es de 60 metros por píxel, lo que empeora el filtrado de las capas con resoluciones más precisas.

- **Librería s2cloudless de Python** ¹⁰: El algoritmo s2cloudless, es un detector de nubes basado en aprendizaje automático para imágenes Sentinel-2. Utiliza LightGBM para clasificar píxeles basándose en sus respuestas espectrales, y aplica operaciones morfológicas para refinar las máscaras de nubes, logrando resultados superiores a otros algoritmos de una sola escena de acuerdo con Zupanc, 2017.

Este algoritmo fué desarrollado por el equipo de investigación en SentinelHub, se validó junto con otros nueve algoritmos en cuatro conjuntos de datos de prueba diferentes y, en todos los casos, se encontró que estaba en el frente de Pareto, véase Skakun et al., 2022. Su integración en el flujo de trabajo ya dependiente de la API de Sentinel Hub sería especialmente sencillo.

- **Braaten-Cohen-Yang cloud detector**: Se trata de un algoritmo tan sencillo que se podría añadir directamente al *evalscript*¹¹ al solicitar de lecturas satelitales, sin necesidad de hacer más solicitudes de máscaras a la API o de calcular estas máscaras. Desafortunadamente con un 73 % de precisión (véase Braaten et al., 2015) queda como alternativa.

- **Hollstein's cloud detection algorithm**: Este algoritmo presenta una accuracy del 98 % empleandose la aproximación bayesiana. Desafortunadamente, la única implementación encontrada ¹² está anticuada y el esfuerzo para desarrollar una implementación nueva no compensa la poca mejora respecto del resto de opciones.

Tras evaluar las alternativas, se selecciona la librería de Python s2cloudless. Esta decisión se fundamenta en su demostrado alto rendimiento en la detección de nubes, validado en la literatura científica, y en su sencilla integración en el flujo de trabajo desarrollado en Python para el preprocesamiento de los datos.

A.2.2. Filtrado de píxeles sin agua

Las zonas que se encuentren secas dentro de la región que comprende un embalse no pueden dar lugar a floraciones así que dado el propósito de este trabajo no serán analizadas. Dado que la solicitud de lecturas satelitales se hace de la región completa de un embalse y que las zonas secas de un embalse cambian durante el año, los píxeles que correspondan a una zona sin agua deberán ser descartados durante el preprocesamiento.

¹⁰Véase el [repositorio en Github](#)

¹¹El evalscript ya desarrollado [aquí](#)

¹²Implementación en el [repositorio de Github](#)

Para el filtrado de píxeles sin agua se emplea el *Índice de diferencia de agua normalizado* (NDWI) cuya fórmula para la misión Sentinel-2 es $NDWI = (B_3 - B_8) / (B_3 + B_8)$, donde B_3 corresponde a la banda del verde y B_8 a la del infrarrojo cercano (NIR). Adicionalmente, se considera el *Índice de Agua de Diferencia Normalizada Modificado* (mNDWI), se decide descartar la idea por el riesgo de que malinterprete la nieve como agua (Huang et al., 2018) lo que resultaría en medidas incorrectas en partes secas de los embalses sobre las que haya nevado.

A.2.3. Descripción del algoritmo de filtrado global

Para la solicitud y preprocesamiento de lecturas satelitales de varias bandas espectrales que cumplan las condiciones antes listadas, se emplea el algoritmo 1 que, dada la información geográfica de un embalse y una lista de fechas para las que exista una lectura satelital de dicho embalse, devuelve una lista que contiene únicamente las lecturas satelitales tomadas en alguna de las fechas dadas que tengan más de un determinado porcentaje de *píxeles válidos*.

Dicho algoritmo, para cada fecha provista, emplea la función 'ApiReqRez' descrita en A.1.1 para obtener 2 máscaras de datos que actuarán como filtros, descartando el valor de todo píxel de una zona sin agua o cubierta por nubes dejando dicho valor a 0. Si el número de píxeles que dichos filtros no descartan (i.e. los píxeles válidos en la imagen) no está por encima de un umbral, la imagen en dicha fecha se descarta. En cambio, si el número de píxeles válidos en la imagen supera dicho umbral, se realiza la solicitud de la imagen satelital deseada y a esta se le aplican los filtros, añadiéndola a la lista.

Nótese que las solicitudes a la API de SentinelHub son el principal cuello de botella de los algoritmos en este proyecto. Son costosas en tiempo y los recursos computacionales que emplean pueden resultar costosos económicamente. Así pues que en el algoritmo se realiza la comprobación de que el filtrado no descartará el valor de demasiados píxeles antes de realizar la solicitud de una lectura satelital de varias bandas espectrales, pues estas son muy costosas y solicitar un filtro de nubes o de ausencia de agua en forma de máscara de datos es más rápido y económico.

En las pruebas se hace uso del algoritmo 1, añadiendo algo de complejidad para poblar una estructura de datos (concretamente un DataFrame de la librería pandas¹³) con la forma [fechas, bandas], que esencialmente almacena las lecturas satelitales de un pantano tomadas dentro de un periodo de tiempo determinado, con el fin de crear las curvas de progreso de la reflectancia de diferentes bandas espectrales o combinaciones de las mismas en función del tiempo. En esta estructura cada fila almacena la información del pantano capturada por el satélite en una fecha en concreto, y para una misma fila en cada columna se almacena el promedio del valor de los píxeles válidos de la lectura del pantano para una banda o combinación en concreto.

¹³Véase la [documentación](#)

A.3. Evaluación de los posibles indicadores

Una vez determinada cuál será la fuente de datos con las que se trabaja, se seleccionan los indicadores de eutrofización en un embalse que servirán como entrada al modelo. Las primeras posibilidades serán las imágenes de las **12 bandas espectrales disponibles de la misión Sentinel L2A, el NDVI y la temperatura en el embalse**. El NDVI, o *Índice de Vegetación de Diferencia Normalizada*, es esencialmente la combinación lineal de las reflectancias de las bandas 8 y 4 y se utiliza como indicador del nivel de vegetación. Para los propósitos de esta investigación, el NDVI se tratará del mismo modo que cualquier otra combinación de bandas espectrales. Para determinar cuáles de los posibles indicadores son más representativos se realizan estudios visuales y correlacionales del progreso de los valores de cada posible indicador.

Para la temperatura esta evolución se representa mediante una curva de temperatura en el embalse en función de la fecha.

Si el indicador es una banda espectral o combinación de las mismas (el NDVI y cualquier otro índice es esencialmente una combinación de bandas) se emplea el algoritmo 1 de solicitud y filtrado de imágenes satelitales. Este se aplica añadiendo funcionalidades para poblar una estructura de datos (concretamente un *DataFrame* de la librería pandas ¹⁴) con la forma [fechas, bandas], que esencialmente almacena las lecturas satelitales de un pantano tomadas dentro de un periodo de tiempo determinado, con el fin de crear las curvas de progreso de la reflectancia de diferentes bandas espectrales o combinaciones de las mismas en función del tiempo. En esta estructura cada fila almacena la información del pantano capturada por el satélite en una fecha en concreto, y para una misma fila en cada columna se almacena el promedio del valor de los píxeles válidos de la lectura del pantano para una banda o combinación en concreto. Más concretamente:

- Si el indicador estudiado es una **banda espectral** el valor de la curva en cada fecha se calcula promediando los valores de los píxeles válidos de la imagen tomada en dicha fecha y en esa banda. Por ejemplo, Si el indicador es la banda 2 (longitud de onda del azul) cada píxel válido en la imagen de una fecha determinada representa la reflectancia en la región azul del espectro para el área del embalse cubierta por ese píxel. El valor de la curva para esa fecha es el promedio de estas reflectancias en la banda azul para la totalidad del embalse. En otras palabras, el valor de la curva para esa fecha representará la 'cantidad de azul' reflejada por el embalse en dicha fecha.
- Si el indicador estudiado es una **combinación de bandas**, las curvas se derivan de manera análoga a las bandas individuales. La diferencia radica en que el valor de cada píxel en la imagen satelital resultante representa la combinación lineal de los valores de los píxeles correspondientes en las imágenes de las bandas combinadas. Por ejemplo, para el NDVI, calculado con la fórmula $(B_8 B_4) / (B_8 + B_4)$, el valor de cada píxel en las imágenes utilizadas para describir su curva corresponde a

¹⁴Véase la [documentación](#)

$(P_8 P_4) / (P_8 + P_4)$, donde P_8 y P_4 son, respectivamente, los valores de dicho píxel en la misma fecha para las bandas 8 y 4.

Para este estudio se presta especial atención a varios periodos delimitados entre **2 meses antes y 1 mes después** de la detección de un evento eutrofización por parte de la CHE. Este estudio se centrará en el embalse del Val, en el que tuvieron lugar 3 de estos eventos, detectados respectivamente el **4 de julio de 2018**, el **10 de julio de 2020** y el **10 de septiembre de 2020**, según medidas de la CHE facilitadas para esta investigación (véase A.1).

Fecha	Biovolumen TOTAL fitoplancton (mm ³ /L)	Biovolumen de cianobacteria (mm ³ /L)	% cianobacteria (dato anual)	Densidad fitoplancton del taxón de cianobacteria más abundante (cel/mL)	Taxón	Género y especie	Observación
07/08/2012	2.44	0.19053	56.63	10336	CHRODISPO	<i>Chroococcus dispersus</i>	Hay otras especies de cianobacterias con alta presencia como <i>Aphanocapsa</i> sp. 5586.78 cel/mL y <i>Anabaena</i> sp. 1117.36 cel/mL.
09/09/2013	5.88	0.02369	9.54	2235	APHASGENO	<i>Aphanocapsa</i> sp.	Es el tercer taxón más abundante. También hay presencia de <i>Microcystis flos-aquae</i> 4210.42 cel/mL.
29/06/2015	2.17	0.06598	5.31	187	ANABELENO	<i>Anabaenopsis elenkinii</i>	Es el sexto taxón más abundante.
27/07/2016	2.50	0.33812	26.19	14224	APHASGENO	<i>Aphanocapsa</i> sp.	<i>Microcystis flos-aquae</i> 2247 cel/mL.
13/06/2017	3.38	0.572	16.82	4525	APHAGRACO	<i>Aphanizomenon gracile</i>	<i>Merismopedia tenuissima</i> 3641 cel/mL, <i>Anabaenopsis elenkinii</i> 1427 cel/mL, <i>Microcystis flos-aquae</i> 1337 cel/mL.
12/09/2017	43.54	0.072	0.02	352	APHAGRACO	<i>Aphanizomenon gracile</i>	<i>Microcystis flos-aquae</i> 333 cel/mL.
04/07/2018	8.80	3.903	44.36	36513	APHAGRACO	<i>Aphanizomenon gracile</i>	<i>Microcystis flos-aquae</i> 5184 cel/mL y <i>Anabaenopsis elenkinii</i> 1819 cel/mL.
09/07/2019	7.35	0.173	2.35	2917	ANAPCIRCO	<i>Anabaenopsis circularis</i>	Es el segundo taxón más abundante.
10/07/2020	42.37	9.232	67.61	32435	APH002KLE0 09	<i>Aphanizomenon klebahnii</i>	
10/09/2020	13.65	2.613	6.17	84985	APH002GENE	<i>Aphanizomenon</i> sp.	
16/07/2021	4.31	0.380	8.96	1903	APH002GENE	<i>Aphanizomenon</i> sp.	<i>Dolichospermum mendotae</i> 1852 cel/mL.
10/09/2021	30.17	0.083	0.27	761	APH002GENE	<i>Aphanizomenon</i> sp.	
08/07/2022	68.00	0.683	1.00	7015	APH002KLE0 09	<i>Aphanizomenon klebahnii</i>	<i>Dolichospermum mendotae</i> 1224 cel/mL.
20/09/2022	68.02	0.030	0.04	1697	MIC003GENE	<i>Microcystis</i> sp.	

Figura A.1.: Registro de mediciones de concentraciones de cianobacterias proporcionadas por la Confederación Hidrográfica del Ebro

Para las pruebas en las que se estudiará la similaridad entre curvas de distintos años se han estudiado varios coeficientes de correlación con los que capturar parecidos y diferencias entre dichas curvas, y tras considerar los coeficientes más populares se decide emplear el coeficiente de correlación de Pearson¹⁵.

Se emplea el **coeficiente de correlación de Pearson**, ρ , y no otros también populares como el de **Spearman** o el de **Kendall**, por ejemplo, porque las curvas que se van a comparar, aunque de años distintos, describen información de la misma banda espectral: se espera que en las mismas condiciones los valores para una banda en concreto sean linealmente similares a los de otro año en condiciones similares.

¹⁵Sobre el [coeficiente de Pearson](#)

Los coeficientes de Spearman y Kendall son menos apropiados porque capturan relaciones monotónicas y no lineales.

A.3.1. Estudio de cada periodo problemático

Como primera aproximación, se elige la metodología más evidente, si bien se preveía su limitada capacidad resolutoria: Para cada periodo correspondiente a un evento problemático se crea una gráfica con una curva por cada banda, que ilustra el progreso de estos indicadores durante dicho periodo. Dado que hay muchas fechas en las que la imagen satelital correspondiente no tiene píxeles válidos suficientes (para la definición de píxeles válidos ver A.2) se ha decidido emplear interpolación *spline* de orden 2¹⁶. Se ha escogido esta interpolación para conseguir curvas más suaves que con la interpolación lineal pero empleando polinomios de grado 2 para evitar demasiada complejidad, dado que la variabilidad de las curvas no se prevee excesiva.

Las tres gráficas resultantes, 2.1, con y sin interpolación, sugieren visualmente que las bandas 3 y 9 muestran incrementos significativos en las proximidades de las detecciones de eutrofización. No obstante, a pesar de que todas las bandas muestran un pico durante la detección del tercer evento, no se obtienen conclusiones definitivas, lo que justifica la realización de pruebas adicionales.

A.3.2. Estudio correlacional de cada banda

A continuación se estudia, banda por banda, la evolución de los promedios en 4 periodos distintos: **del 4 de mayo al 4 de agosto de los años 2017, 2018, 2019 y 2020**. Dichas fechas para los años 2018 y 2020 son un '*periodo problemático*', es decir un periodo de tiempo alrededor de un evento detectado de eutrofización por parte de la CHE; en los años 2017 y 2019, en cambio, durante esas fechas no hubo un alto nivel de alerta por eutrofización. Estos son los '*periodos no problemáticos*'.

Se grafican las curvas de cada banda y del NDVI como se describe en la introducción de este anexo, pero esta vez creando una gráfica para cada banda. En cada gráfica se muestran las cuatro curvas de dicha banda en cada periodo.

El objetivo de esta prueba es determinar si alguna banda o el NDVI muestran un comportamiento diferenciado entre los periodos problemáticos y los periodos sin problemas, y viceversa. Una banda que se comporte de manera claramente distinta para las etapas con y sin problemas se consideraría un indicador prometedor.

Para determinar si alguna banda se comporta así se producen las gráficas 2.1 y A.3 y se buscan similitudes entre las curvas de periodos problemáticos y, por otro lado, similitudes entre las curvas de los periodos sin problemas. Además, para más precisión, se computan las tablas de correlaciones entre las curvas de cada gráfica, empleando como ya se ha explicado en la introducción de este anexo el

¹⁶Ver la [wikipedia](#) sobre la interpolación spline

coeficiente de correlación de Pearson, para cuantificar la similitud entre curvas. Así pues, se busca una tabla en la que: - Los coeficientes de correlación entre los años problemáticos (2018 y 2020) sean altos - Los coeficientes de correlación entre los años no problemáticos (2017 y 2019) sean altos - Los coeficientes de correlación entre los años problemáticos y los años no problemáticos (el resto de combinaciones de años) sean bajos

Como nota, para las pruebas de ahora en adelante los polinomios de la interpolación *spline* serán de orden 3 para incrementar la precisión de las curvas, con la intención de extraer conclusiones más reveladoras con un volumen más grande de pruebas que salve cualquier sobreestimación de valores intermedios.

Anexo A. Análisis de la viabilidad del modelo objetivo



Figura A.2.: Reflectancia de cada banda para los periodos de 2017, 2018, 2019 y 2020

Anexo A. Análisis de la viabilidad del modelo objetivo

Coeficientes de correlación para la banda B01

	2017	2018	2019	2020
2017	1	-0.3330	0.2021	-0.3355
2018	-0.3330	1	0.2204	0.4882
2019	0.2021	0.2204	1	0.1644
2020	-0.3355	0.4882	0.1644	1

(a)

Coeficientes de correlación para la banda B03

	2017	2018	2019	2020
2017	1	0.3480	0.6271	0.4762
2018	0.3480	1	0.6651	0.7566
2019	0.6271	0.6651	1	0.7541
2020	0.4762	0.7566	0.7541	1

(c)

Coeficientes de correlación para la banda B05

	2017	2018	2019	2020
2017	1	0.6155	0.5606	0.5359
2018	0.6155	1	0.6343	0.7214
2019	0.5606	0.6343	1	0.7506
2020	0.5359	0.7214	0.7506	1

(e)

Coeficientes de correlación para la banda B07

	2017	2018	2019	2020
2017	1	0.2055	0.4712	0.3261
2018	0.2055	1	0.5291	0.6063
2019	0.4712	0.5291	1	0.6707
2020	0.3261	0.6063	0.6707	1

(g)

Coeficientes de correlación para la banda B8A

	2017	2018	2019	2020
2017	1	0.1052	0.3452	0.2501
2018	0.1052	1	0.4949	0.5201
2019	0.3452	0.4949	1	0.6535
2020	0.2501	0.5201	0.6535	1

(i)

Coeficientes de correlación para la banda B11

	2017	2018	2019	2020
2017	1	0.2162	0.1102	0.1633
2018	0.2162	1	0.4962	0.1171
2019	0.1102	0.4962	1	0.2073
2020	0.1633	0.1171	0.2073	1

(k)

Coeficientes de correlación para la banda NDVI

	2017	2018	2019	2020
2017	1	0.6969	0.2122	0.2255
2018	0.6969	1	-0.1028	0.0121
2019	0.2122	-0.1028	1	0.1631
2020	0.2255	0.0121	0.1631	1

(m)

Coeficientes de correlación para la banda B02

	2017	2018	2019	2020
2017	1	0.1180	0.5899	-0.3134
2018	0.1180	1	0.4222	0.4846
2019	0.5899	0.4222	1	0.1414
2020	-0.3134	0.4846	0.1414	1

(b)

Coeficientes de correlación para la banda B04

	2017	2018	2019	2020
2017	1	0.2691	0.5093	0.3752
2018	0.2691	1	0.5350	0.6513
2019	0.5093	0.5350	1	0.6769
2020	0.3752	0.6513	0.6769	1

(d)

Coeficientes de correlación para la banda B06

	2017	2018	2019	2020
2017	1	0.2082	0.5192	0.3540
2018	0.2082	1	0.5129	0.6128
2019	0.5192	0.5129	1	0.6681
2020	0.3540	0.6128	0.6681	1

(f)

Coeficientes de correlación para la banda B08

	2017	2018	2019	2020
2017	1	0.4551	0.6410	0.4788
2018	0.4551	1	0.5196	0.5440
2019	0.6410	0.5196	1	0.6720
2020	0.4788	0.5440	0.6720	1

(h)

Coeficientes de correlación para la banda B09

	2017	2018	2019	2020
2017	1	-0.3367	0.2061	-0.1664
2018	-0.3367	1	0.0520	0.5988
2019	0.2061	0.0520	1	0.1519
2020	-0.1664	0.5988	0.1519	1

(j)

Coeficientes de correlación para la banda B12

	2017	2018	2019	2020
2017	1	0.0659	-0.0161	0.0813
2018	0.0659	1	0.4551	0.1692
2019	-0.0161	0.4551	1	0.1577
2020	0.0813	0.1692	0.1577	1

(l)

Figura A.3.: Correlaciones de cada banda para los periodos de 2017, 2018, 2019 y 2020

El análisis visual de las gráficas no revela una banda espectral que se destaque como un indicador prometedor. De hecho, se observa una mayor similitud entre las curvas de 2017 y 2018, y entre las de 2019 y 2020, lo cual no corresponde con la correlación esperada. Las tablas de coeficientes de correlación tampoco muestran resultados más reveladores. Aunque para bandas como la 3 o la 5, las correlaciones que deberían ser elevadas lo son, las correlaciones que deberían ser bajas también presentan valores similares. Por consiguiente, se procede a realizar pruebas adicionales.

A.3.3. Estudio de la temperatura como indicador

Como se ha explicado en [A.1.2](#) se estudia la viabilidad de emplear la temperatura en el embalse como indicador de eutrofización. Este estudio se centrará también en el embalse de El Val, del que dispone del registro de temperaturas de casi todas las fechas desde 2016 hasta 2023, provisto por la CHE para este estudio. Para estas pruebas se emplea la misma metodología que en la anterior: Usando los datos cedidos por la confederación se van a dibujar las curvas del progreso de la temperatura del 4 de mayo al 4 de agosto de, 4 años distintos: 2 problemáticos (2018 y 2020) y 2 no problemáticos (2019 y 2022). En este punto se cambia 2017 por 2022 como año no problemático porque uno de los satélites (Sentinel 2B) se lanzó a mediados del 2017 por lo que previo al lanzamiento hay la mitad de imágenes. Ya que se dispone de las temperaturas máxima y mínima de cada día se escogen los siguientes posibles indicadores de eutrofización, cuyas curvas se dibujarán para su estudio:

- Temperatura media del día
- Temperatura mínima
- Temperatura máxima
- El ratio entre las temperaturas mínima y máxima (T_{max}^a / T_{min}^a)

Los valores de estos posibles indicadores se normalizan al intervalo $[0,1]$ y se obtienen las gráficas [A.4](#) y [A.5](#).

Anexo A. Análisis de la viabilidad del modelo objetivo




Figura A.4.: Progreso de las formas de T^a en el embalse

Coefficientes de correlación: Temperatura Media

	2018	2019	2020	2022
2018	1	0.6385	0.6730	0.4171
2019	0.6385	1	0.4281	0.4156
2020	0.6730	0.4281	1	0.1335
2022	0.4171	0.4156	0.1335	1

(a)

Coefficientes de correlación: MinMax Ratio

	2018	2019	2020	2022
2018	1	0.1208	-0.1405	0.1504
2019	0.1208	1	0.1060	0.1918
2020	-0.1405	0.1060	1	-0.0108
2022	0.1504	0.1918	-0.0108	1

(b)

Coefficientes de correlación: Temperatura Minima

	2018	2019	2020	2022
2018	1	0.6843	0.6003	0.4330
2019	0.6843	1	0.4869	0.4438
2020	0.6003	0.4869	1	0.1181
2022	0.4330	0.4438	0.1181	1

(c)

Coefficientes de correlación: Temperatura Maxima

	2018	2019	2020	2022
2018	1	0.5482	0.6475	0.3762
2019	0.5482	1	0.3309	0.3681
2020	0.6475	0.3309	1	0.1273
2022	0.3762	0.3681	0.1273	1

(d)

Figura A.5.: Correlaciones de la temperatura en distintos periodos

Las gráficas obtenidas presentan una oscilación excesiva y ofrecen poca información concluyente. El único patrón consistente, con la excepción del ratio entre temperaturas mínima y máxima, es el aumento de la temperatura a medida que se aproxima agosto, lo cual es predecible.

En la gráfica del ratio entre temperatura máxima y mínima se aprecian similitudes entre dos pares de años, observándose que los ratios de 2018 y 2019 presentan menor oscilación en comparación con los de 2020 y 2022. Sin embargo, estas similitudes carecen de relevancia para el propósito de esta investigación, dado que son los años problemáticos (2018 y 2020) los que deberían exhibir similitud entre sí y diferenciarse de los años no problemáticos (2019 y 2022).

Las tablas de correlación tampoco revelan patrones prometedores de similitud y diferencia. Aunque los años 2018 y 2020 muestran una correlación considerable para todos los indicadores excepto el ratio, la correlación entre los años no problemáticos (2019 y 2022) no es significativamente mayor que la observada entre otras combinaciones de años. Esto conduce a la conclusión de que la temperatura no se empleará como indicador.

A.3.4. Estudio de las combinaciones de bandas más reveladoras

Con el asesoramiento del tutor y la experiencia del Dr. Mario Esteban, un experto en el campo, se seleccionan 2 bandas que denoten un comportamiento especialmente diferenciado entre los periodos con y sin problemas. Empleando los resultados presentados en A.3.2, y tras una larga consideración se escogen las bandas espectrales 9 y 11 como las más indicativas de la eutrofización. Se espera que una combinación lineal de estas dos bandas pueda ser más reveladora que cada una por separado.

Para estudiar dichas combinaciones, primeramente se crean las curvas para las combinaciones $B_{09} * B_{11}$ y B_{09} / B_{11} de la manera que se ha explicado al principio de esta sección. A continuación se realizan pruebas de la misma naturaleza que las pruebas en apartados anteriores, para determinar la viabilidad de dichas combinaciones como indicadores de eutrofización. De nuevo, se toma el periodo del 4 de mayo al 4 de agosto de 2 años problemáticos y 2 años no problemáticos, asumiendo que un buen indicador será aquel para el que las curvas de años problemáticos sean similares entre sí y distintas a las curvas de años no problemáticos, siendo estas a su vez similares entre sí.

Anexo A. Análisis de la viabilidad del modelo objetivo




Figura A.6.: Progresos de las reflectancias de las combinaciones de bandas estudiadas

Coefficientes de correlación para la combinación B09/B11

	2018	2019	2020	2022
2018	1	-0.3805	0.3503	-0.5944
2019	-0.3805	1	0.1683	0.6616
2020	0.3503	0.1683	1	-0.2015
2022	-0.5944	0.6616	-0.2015	1

(a)

	2018	2019	2020	2022
2018	1	0.2830	0.6489	0.2857
2019	0.2830	1	0.2315	0.5498
2020	0.6489	0.2315	1	0.1971
2022	0.2857	0.5498	0.1971	1

(b)

Figura A.7.: Correlaciones de las posibles combinaciones de bandas

Los resultados obtenidos, presentados en las gráficas A.6 y las tablas A.7, son notablemente más prometedores. Las curvas correspondientes a los años problemáticos (2018 y 2020) exhiben patrones de crecimiento y decrecimiento altamente similares entre sí. De particular interés es la presencia de picos pronunciados en ambos casos a principios de julio, coincidiendo con la detección de los eventos de eutrofización por parte de la CHE

El examen de las tablas de correlación sugiere que estas combinaciones pueden ser indicadores eficaces. Particularmente para la combinación $B_{09} * B_{11}$, las correlaciones entre 2018 y 2020, y entre 2019 y 2022, son notablemente superiores, excediendo 0.5, mientras que el resto de las correlaciones no superan 0.3.

En conclusión, a la espera de la realización de pruebas adicionales, la combinación $B_{09} * B_{11}$ se selecciona como el indicador de eutrofización para el entrenamiento de los modelos de aprendizaje automático.

A.3.5. Pruebas mezclando combinaciones de bandas con temperaturas

Si bien se ha deducido que la temperatura en el embalse no es un indicador adecuado para detectar la eutrofización, se hipotetiza que la combinación de otros indicadores con la temperatura podría mejorar la precisión y fiabilidad del modelo.

Partiendo de esta hipótesis se realizan varias pruebas para determinar si se puede obtener un indicador mejor que las combinaciones de bandas ya discutidas mezclando las mismas con la temperatura mínima, la máxima, la temperatura media o el ratio T_{max}^a / T_{min}^a .




Figura A.8.: Reflectancias de la T^a media con $B_{09} * B_{11}$ y B_{09} / B_{11}

De nuevo, a través de todas estas pruebas se usarán las fechas del 4 de mayo al 4 de agosto de los años 2018, 2019, 2020 y 2022 para comprobar si las curvas de periodos problemáticos son similares entre sí y diferentes a las curvas de periodos no problemáticos de igual manera y con el mismo propósito que en anteriores pruebas.

A.3.5.1. Combinaciones de bandas y temperatura media

Para determinar si la temperatura media puede mejorar las ya estudiadas combinaciones de bandas como indicador de eutrofización se realizan varias pruebas:

Se grafican las curvas de temperatura de cada año junto con las curvas de las combinaciones de bandas ya discutidas, todas ellas creadas con los valores normalizados al intervalo $[0, 1]$.

En el resultado, [A.8](#) las curvas de la reflectancia de la combinación de bandas son las 4 primeras en la leyenda, y las curvas de la temperatura media son las 4 siguientes.

No se observa una similitud aparente entre la reflectancia y la temperatura en estas gráficas iniciales. Por lo tanto, se opta por graficar, de forma independiente para cada año, las curvas de reflectancia de las combinaciones de bandas junto con las curvas de la temperatura media.

Considerando los resultados, [A.9](#), las ocho gráficas y los coeficientes de correlación calculados (en los títulos, no se observa apenas similitud entre la temperatura y la reflectancia, con solo una o dos excepciones).

Anexo A. Análisis de la viabilidad del modelo objetivo




Figura A.9.: Curvas de la T³ media y de las combinaciones estudiadas año por año

Anexo A. Análisis de la viabilidad del modelo objetivo




Figura A.10.: Progreso del producto de la T^a media y las reflectancias de interés

Correlaciones comb. B09/B11* T^a media:

	2018	2019	2020	2022
2018	1	-0.3761	0.5305	-0.5096
2019	-0.3761	1	-0.0245	0.2169
2020	0.5305	-0.0245	1	-0.1576
2022	-0.5096	0.2169	-0.1576	1

(a)

Correlaciones comb B09*B11* T^a media:

	2018	2019	2020	2022
2018	1	0.4453	0.7004	0.1584
2019	0.4453	1	0.4118	0.3806
2020	0.7004	0.4118	1	-0.0404
2022	0.1584	0.3806	-0.0404	1

(b)

Figura A.11.: Correlaciones del producto de la T^a media y las reflectancias de interés

Finalmente, para determinar la idoneidad de la temperatura media, se procede a graficar el producto de la temperatura media con los valores de reflectancia para cada fecha, obteniendo las tablas A.11 y las gráficas A.10. Los resultados evidencian la ausencia de similitudes consistentes entre los pares de años problemáticos por un lado y los no problemáticos por otro, así como la falta de diferencias consistentes entre dichas parejas. En consecuencia, se descarta el uso de la temperatura media para mejorar las combinaciones de bandas como indicadores de eutrofización.

A.3.5.2. Combinaciones de bandas y ratio entre temperatura máxima y mínima

Tras la temperatura media se procede a comprobar si el ratio entre la temperatura mínima y máxima en el pantano (T_{max}^a/T_{min}^a) puede resultar de utilidad si se usa junto con las combinaciones de bandas ya obtenidas. Para esta comprobación se realizarán las mismas pruebas que en el apartado anterior.

Primeramente, se dibujan en las gráficas A.12 las curvas del ratio (las 4 últimas curvas en la leyenda) junto con las curvas de una combinación de bandas (las 4 primeras curvas en la leyenda) y se comprueba que, a primera vista, hay pocas similitudes entre ambos conjuntos de curvas.

Anexo A. Análisis de la viabilidad del modelo objetivo




Figura A.12.: Primera prueba con el ratio T_{max}^a/T_{min}^a

Posteriormente, se grafican las curvas del ratio entre temperatura máxima y mínima junto con las curvas de las combinaciones de bandas, generando una gráfica para cada año [A.13](#). De forma similar a las pruebas previas, no se alcanzan conclusiones positivas, salvo en un par de casos donde el coeficiente de correlación de Pearson muestra una significancia ligeramente mayor.

Anexo A. Análisis de la viabilidad del modelo objetivo




Figura A.13.: Curvas del ratio $T^a_{Max/min}$ y de las combinaciones estudiadas año por año

Anexo A. Análisis de la viabilidad del modelo objetivo



Figura A.14.: Progreso del producto del ratio T_{max}^a/T_{min}^a y las reflectancias de interés

Correlaciones con coef. de Pearson:

	2018	2019	2020	2022
2018	1	0.1360	-0.0487	-0.1618
2019	0.1360	1	0.0626	0.2639
2020	-0.0487	0.0626	1	-0.2348
2022	-0.1618	0.2639	-0.2348	1

Correlaciones con coef. de Pearson:

	2018	2019	2020	2022
2018	1	0.0322	0.3632	-0.1541
2019	0.0322	1	-0.0479	0.4302
2020	0.3632	-0.0479	1	-0.2217
2022	-0.1541	0.4302	-0.2217	1

(a) Correlaciones del producto $B_{09}/B_{11} * T_{max}^a/T_{min}^a$

(b) Correlaciones del producto $B_{09} * B_{11} * T_{max}^a/T_{min}^a$

Figura A.15.: Correlaciones del producto del ratio T_{max}^a/T_{min}^a y las reflectancias de interés

Para terminar, se representan las curvas del producto del ratio T_{max}^a/T_{min}^a y las combinaciones de bandas $B_{09} * B_{11}$ y B_{09}/B_{11} , de manera análoga al apartado anterior. Se constata nuevamente que las curvas correspondientes a los períodos problemáticos no difieren sustancialmente de las de los periodos no problemáticos. Los resultados, A.14 y A.15, indican una escasa relación entre las combinaciones de bandas y el ratio de temperaturas que justifique la continuidad de su estudio conjunto con los indicadores ya establecidos.

A.3.5.3. Combinación de bandas y temperaturas mínimas y máximas

El análisis de los resultados de las pruebas previas permite concluir que la combinación B_{09}/B_{11} presenta un rendimiento consistentemente inferior a la combinación $B_{09} * B_{11}$ en lo que a separabilidad de periodos problemáticos con periodos no problemáticos se refiere. Por lo tanto, se descarta como indicador de eutrofización y no se empleará en las pruebas subsiguientes, simplificando así las próximas pruebas.

A continuación se estudia la utilidad de las temperaturas máximas y mínimas en el embalse como indicadores de la eutrofización.

De manera similar a las pruebas previas, se representa la evolución de la temperatura mínima junto con la de la combinación $B_{09} * B_{11}$ para los cuatro periodos problemáticos y no problemáticos mencionados. Las gráficas resultantes A.16 demuestran una baja similitud entre la temperatura mínima y la combinación $B_{09} * B_{11}$ como indicadores.




Figura A.16.: Curvas de la Tª mínima junto con la reflectancia de $B_{09} * B_{11}$

Posteriormente, se replica la prueba empleando la temperatura máxima, con la expectativa de que las temperaturas elevadas puedan indicar una menor absorción de calor por parte del cuerpo de agua, potencialmente debido a la cobertura vegetal asociada a la eutrofización. Sin embargo, como se observa en la figura A.17, se constata que no hay apenas similitudes entre el indicador previamente validado como moderadamente efectivo y las temperaturas máximas.



Figura A.17.: Curvas de la T^a mínima junto con la reflectancia de $B_{09} * B_{11}$

Anexo A. Análisis de la viabilidad del modelo objetivo




Figura A.18.: Progreso del producto de la T^a máxima y mínima con la reflectancia de $B_{09} * B_{11}$

Corr. matrix (coef de Pearson) de $B_{09} * B_{11} * T^a_{min}$: Corr. matrix (coef de Pearson) de $B_{09} * B_{11} * T^a_{max}$:

	2018	2019	2020	2022
2018	1	0.5128	0.6137	0.3107
2019	0.5128	1	0.5766	0.3191
2020	0.6137	0.5766	1	0.0119
2022	0.3107	0.3191	0.0119	1

(a)

	2018	2019	2020	2022
2018	1	0.4915	0.6845	0.1169
2019	0.4915	1	0.4506	0.3105
2020	0.6845	0.4506	1	-0.0787
2022	0.1169	0.3105	-0.0787	1

(b)

Figura A.19.: Correlaciones del producto del ratio T^a_{max}/T^a_{min} y las reflectancias de interés

Para terminar, de acuerdo con la metodología empleada en pruebas anteriores, se calcula el producto de la combinación de bandas $B_{09} * B_{11}$ con las temperaturas máximas y mínimas. Se generan las gráficas A.18, y las tablas de coeficientes de correlación A.19. Si bien es cierto que con las temperaturas máximas los resultados son moderadamente mejores, evidenciando mayores similitudes entre periodos de la misma naturaleza y mayores diferencias entre periodos problemáticos y no problemáticos, en ambos casos el periodo problemático de 2019 exhibe una correlación más intensa con el periodo no problemático de 2020 que con el periodo de la misma naturaleza en 2022.

Por consiguiente, se concluye que ni la temperatura mínima ni la máxima aportan una utilidad significativa en combinación con $B_{09} * B_{11}$ para la predicción de la eutrofización.

Anexo B.

Desarrollo del modelo de clasificación

B.1. Obtención y preprocesamiento de conjunto de datos para entrenamiento

Una vez estudiados los indicadores más adecuados para la predicción de la eutrofización, el siguiente paso se centra en la creación de un corpus de datos para el entrenamiento de los modelos que se van a probar. Este corpus se construirá a partir de muestras que, para un pantano y fecha específicas, recogen tanto el valor de la **combinación indicador de bandas espectrales previamente escogida** como la **concentración de cianobacterias**, categorizada según los cuatro niveles de alerta establecidos por la OMS (ver figura 1.1).

Dado que la frecuencia de lecturas satelitales de una misma zona es de varios días, no se puede obtener el valor de la combinación de bandas espectrales para cada fecha en la que haya una medida de concentración de cianobacterias. Así pues, para aquellas mediciones de cianobacterias sin una lectura satelital coincidente en la fecha, se les asocia la lectura satelital más cercana en el tiempo.

Dada esta decisión, para enriquecer este corpus y mejorar la capacidad predictiva del modelo se incorpora un atributo adicional denominado '*peso*'. Este atributo cuantifica la diferencia temporal en días entre la fecha de la medición de cianobacterias y la fecha de la lectura satelital del pantano más próxima a dicha medición. Se postula que la inclusión de este atributo permitirá al modelo ponderar la relevancia del valor de la combinación de bandas indicadora en función de la proximidad temporal, asignando una menor importancia a las lecturas satelitales con mayor desfase temporal respecto a la medición de cianobacterias.

Se ha llevado a cabo una exhaustiva investigación para encontrar conjuntos de datos públicamente disponibles que contengan mediciones de concentraciones de cianobacterias, preferiblemente en unidades de $\text{células}/L$ o mm^3/L , junto con la fecha de cada medición. El objetivo es obtener las lecturas satelitales correspondientes a dichas fechas, o en las más cercanas en el tiempo, para la construcción del corpus de datos final.

Como resultado de esta búsqueda se identificaron cuatro conjuntos de datos relevantes, que se denominarán en lo sucesivo como *Dataset1*, *Dataset2*, *Dataset3* y *Dataset4*. A continuación, se presenta una descripción concisa de cada uno:

- **Dataset 1¹**: Contiene información de 20 embalses concretos en los Estados Unidos, pero los datos disponibles se extienden únicamente hasta el año 2018. Esto plantea una limitación, ya que la constelación Sentinel-2 opera completamente, con los satélites Sentinel-2A y Sentinel-2B, desde 2017, luego el número de muestras será limitada.
- **Dataset 2²**: En este conjunto de datos la mayoría de las muestras provienen de ubicaciones distintas, cuya localización habría que averiguar para todas las muestras, pues no se ha encontrado ninguna tabla o índice que relacione los identificadores de las ubicaciones en que se toma la muestra con coordenadas geográficas precisas.

Haciendo unas pruebas se descubre que la ubicación con la mayor cantidad de mediciones de cianobacterias en este conjunto de datos posee solo 15 muestras. El esfuerzo de descifrar qué cuerpos de agua están siendo estudiados en cada localización, resulta una tarea demasiado compleja.

- **Dataset 3, Xue et al., 2024**: Contiene mediciones del lago Taihu en China, con 24 mediciones disponibles desde 2015 y 16 desde 2017. Además de la escasez de mediciones, este conjunto de datos mide el fitoplancton en general, no específicamente las cianobacterias.
- **Dataset 4, Gupta et al., 2024**: Conocido como CAML, este conjunto de datos proporciona mediciones in situ de múltiples puntos en los Estados Unidos. Incluye 13.701 mediciones desde 2017, cada una con la concentración de cianobacterias en células/L y las coordenadas de latitud y longitud del punto en que se hizo la medida.

Los Dataset 1 y 4 se identifican como los más prometedores, debido a la facilidad para obtener lecturas satelitales en el primer caso y a la abundancia de mediciones de concentración de cianobacterias en el segundo. Por consiguiente, se prioriza el preprocesamiento de estos dos conjuntos, manteniendo los otros dos como alternativas en caso de que el 1 y el 4 resulten inviables.

B.1.1. Dataset 1. Pruebas y conclusiones

Partiendo de las medidas de concentraciones de cianobacterias de este conjunto de datos, para completar el conjunto de datos de entrenamiento se requiere la obtención del valor del indicador de eutrofización $B_{09} * B_{11}$ para el embalse y fecha de cada medición. Este proceso implica la realización de solicitudes a la API de Sentinel Hub³ para el día y embalse de cada medida.

¹Más acerca del Dataset 1 en la página catalog.data.gov

²Dataset obtenido de [la página de la EPA](#)

³Más en [la documentación](#)

Y para realizar estas solicitudes es necesario conocer varios detalles sobre el área geográfica cuya lectura satelital se desea solicitar. Estos detalles se han encapsulado en una clase denominada `ReservoirShape` tal que dado un objeto de esta clase con un valor adecuado para todos sus atributos se puede realizar una solicitud exitosa a la API de SentinelHub.

En el *notebook* `geometrias_embalses_dataset1` en el repositorio de este proyecto, se crea, puebla y serializa (utilizando la librería `pickle`⁴) un diccionario con la estructura `{‘id del embalse’ : ReservoirShape}`. Este diccionario almacena un objeto de la clase `ReservoirShape` con sus atributos inicializados correctamente para cada uno de los 20 embalses posibles en los que las mediciones del Dataset 1 pueden haber sido realizadas. El proceso de poblamiento sigue los siguientes pasos:

1. **Obtención de la Geometría básica:** La información geométrica inicial se adquiere manualmente a través de OpenStreetBrowser⁵. Estos son los atributos ‘geometry’, ‘size’ y ‘bbox’ de la clase `ReservoirShape`, que respectivamente corresponden a la forma del embalse, su tamaño y el ‘bounding box’ que es el cuadrilátero circunscrito a la geometría del cuerpo de agua.
2. **Obtención de la Máscara de Datos Más Representativa:** A continuación, mediante una solicitud a la API de SentinelHub se obtiene la máscara de datos más representativa de cada embalse. Para esto se identifica la fecha, dentro de una ventana de 10 días, en la que la tesela satelital capturada sobre el Área de Interés (AOI) del embalse abarca la máxima superficie del mismo.

Esto último se debe a que no todas las solicitudes a la API, incluso con los datos de geometría correctos, devuelven información del mismo área del embalse. La constelación Sentinel, aunque proporciona información global con una frecuencia de 5 días, requiere 10 días para capturar la misma tesela desde el mismo ángulo de visión, lo que justifica la necesidad de seleccionar la imagen con mayor cobertura para cada embalse.

Una vez obtenida la información necesaria para solicitar lecturas satelitales de todos los pantanos, en el *notebook* `primeras_pruebas_Dataset1y4` se intenta construir el conjunto de datos de entrenamiento a partir de las mediciones de cianobacterias del Dataset1. Cada muestra en el buscado conjunto de entrenamiento se compone de los siguientes elementos:

- La **etiqueta a predecir**: La concentración de cianobacterias medida, categorizada según las clases definidas por la OMS ya mencionadas, más una clase adicional para concentraciones superiores a 100.000 células/L ó 10 mm³/L.
- El **atributo ‘promedio’**, que representa el promedio de los valores de los píxeles de la imagen satelital tomada en la fecha más próxima a la medida de

⁴Ver la [documentación](#)

⁵<https://www.openstreetbrowser.org/>

concentración de cianobacterias.

- El **atributo 'peso'**, que cuantifica la diferencia en días entre la medición de cianobacterias y la lectura satelital más cercana.

Tras la ejecución del bucle para generar estas muestras, y el descarte de imágenes afectadas por nubes o ausencia de agua, se obtienen 537 muestras para el conjunto de entrenamiento, lo que representa aproximadamente un tercio de las 1510 medidas de concentración disponibles en el dataset original.

Sin embargo, un análisis adicional revela la existencia de múltiples mediciones para el mismo embalse en la misma fecha dentro del Dataset 1. En otras palabras, en la creación del conjunto de datos original en una misma jornada se realizaron diversas mediciones en cada pantano, algunas en la superficie y otras a 5, 10 o 20 metros de profundidad. Estas medidas exhiben una alta variabilidad, incluso para el mismo día y embalse. El extracto 2.6 obtenido del Dataset 1 ilustra este fenómeno, mostrando las mediciones registradas en 2018 para el lago Buckhorn (identificador 'BHR'), donde todas las medidas corresponden a la misma jornada, con una significativa variabilidad de densidad, incluso entre mediciones a idéntica profundidad.

Esta circunstancia invalida el procedimiento para la creación del conjunto de entrenamiento. La presencia de múltiples medidas de cianobacterias en el mismo día implica que en el conjunto de datos final varias muestras comparten la misma imagen satelital, y por ende el mismo valor para el atributo '*promedio*', mientras que la etiqueta a predecir varía sustancialmente en función de la profundidad en el embalse, un factor que una lectura satelital no puede capturar con precisión.

Dados estos hallazgos, se procede al descarte del Dataset 1. No obstante, el trabajo y el progreso realizados en su preprocesamiento se conservan, ya que serán de utilidad para el tratamiento de otros conjuntos de datos.

B.1.2. Dataset 4. Pruebas y conclusiones

El preprocesamiento del Dataset 4 se estructura en las siguientes fases:

1. **Adquisición de la Geometría de los Cuerpos de Agua:** De manera análoga al intento precedente, la solicitud de lecturas satelitales a la API de Sentinel Hub requerirá de información geográfica acerca del embalse a estudiar. En este conjunto de datos, cada medición de concentración de cianobacterias incluye la localización geográfica en que se realizó el muestreo registrada como la latitud y longitud de la ubicación en grados.

Esta información se emplea para obtener la geometría del cuerpo de agua (embalse, lago, etc.) donde se realizó el muestreo, mediante una solicitud a la API de OpenStreetMap (OSM) ⁶. Esta solicitud se encapsula en la función

⁶<https://wiki.openstreetmap.org/wiki/API>

`get_lake_reservoir_geometry`, que toma como argumentos las coordenadas de la medición y la distancia en metros desde la misma al cuerpo de agua (dato también registrado en cada muestra del Dataset 4), y genera una solicitud a la API de OSM para obtener la información de todo cuerpo de agua en la base de datos de OSM que esté entre las ubicaciones definidas por los parámetros de la función.

Inicialmente, la aplicación de esta función para la instanciación de objetos `ReservoirShape` reveló un porcentaje elevado de fallos en las solicitudes, para las que no se encuentra el cuerpo de agua correspondiente a la medida en la base de OSM.

Adicionalmente, una proporción significativa de las geometrías recuperadas presentaba inconsistencias, como auto-intersecciones o discontinuidades. Esta problemática podría atribuirse a la naturaleza colaborativa de la información geográfica en OSM, donde las geometrías creadas por usuarios anónimos es esperable que presenten imperfecciones.

Afortunadamente, la biblioteca `shapely` ofrece funcionalidades para el tratamiento de geometrías inválidas. Específicamente, el método `buffer`⁷, aplicado a un objeto `Polygon` o `MultiPolygon`, permite corregir dichas imperfecciones.

La aplicación de este método puede resultar en el mismo polígono corregido o en un objeto `MultiPolygon` que contenga los polígonos constituyentes de la forma original, en casos donde la corrección implica una división de la geometría. En tales escenarios, se asume que la forma del cuerpo de agua se describe por el polígono de mayor complejidad resultante de dicha división. Esta decisión se fundamenta en la premisa de que el polígono con mayor número de vértices tenderá a ser el más descriptivo y de mayor extensión del cuerpo de agua, una característica común observada experimentalmente en las geometrías proporcionadas por la API de OSM.

2. **Generación de Máscaras de Datos y Definición de Objetos `ReservoirShape`:** Una vez obtenida la información geométrica del cuerpo de agua de cada medición, se procede a la obtención de las máscaras de datos. Dado que cada muestra corresponde a un cuerpo de agua potencialmente único, se lleva a cabo el proceso de obtención de la máscara de datos para el cuerpo de agua de cada muestra por separado.

Este proceso se realiza de manera análoga al procedimiento empleado en el Dataset 1: Se efectúa una solicitud a la API de Sentinel Hub para identificar la fecha, dentro de un ciclo de 10 días, en la que la tesela capturada sobre el Área de Interés (AOI) del cuerpo de agua abarca la máxima superficie. A continuación esta fecha se utiliza para la solicitud final de la máscara de datos

⁷Más información en la [documentación](#)

del cuerpo de agua correspondiente. Este proceso culmina en la asignación de valores a los atributos de un objeto de la clase `ReservoirShape` para cada lectura de cianobacterias, lo que permite disponer de objetos correctamente definidos para realizar las solicitudes a la API de Sentinel Hub.

3. **Creación del Dataset Final:** Con cada instancia de la clase `ReservoirShape` correctamente inicializada, se procede a efectuar las solicitudes a la API de Sentinel Hub para obtener las lecturas satelitales correspondientes a cada medición. El resultado de estas solicitudes completa el *dataset* final, estructurado como un `DataFrame` que contiene como columnas los campos previamente explicados en la introducción de esta sección 1 de este anexo y, en teoría, una fila por cada medición presente en el Dataset 4.

Sin embargo, es importante señalar que, de las más de 13,000 mediciones de concentraciones de cianobacterias presentes en el dataset original, un porcentaje muy considerable no permite la obtención de una geometría válida, pudiéndose obtener únicamente algo más de 600 áreas de embalses. De las muestras restantes, como ya había ocurrido con otras pruebas, un número significativo de datos no supera los filtros de número de píxeles con agua y sin nubes.

En consecuencia, la disponibilidad final de datos procesables para el análisis se ha visto significativamente reducida. Este hecho subraya la complejidad inherente a la adquisición y validación de información geográfica de fuentes externas, y reafirma la importancia de considerar el elevado porcentaje de datos descartados debido a la presencia de nubes o la ausencia de agua en los cuerpos de agua en el momento de la lectura

B.2. Estudio de modelos de IA candidatos

El presente trabajo aborda un problema de clasificación supervisada cuyo objetivo principal es la detección de concentraciones elevadas de cianobacterias en un embalse a partir de datos satelitales. Así pues se excluyen del alcance de este estudio técnicas como el Análisis de Componentes Principales (PCA) o los métodos de agrupamiento (clustering). El problema a resolver es uno de **clasificación supervisada**, y tras hacer un análisis de posibilidades con el director de este trabajo y experto al respecto, se escogen para su consideración las siguientes técnicas de aprendizaje automático:

Regresión Logística: Este modelo se establece como línea base. Su implementación permite determinar si existe una relación lineal subyacente en el problema y proporciona un punto de referencia para evaluar el rendimiento de modelos más complejos.

Bosques Aleatorios: Estos modelos ofrecen interpretabilidad, lo cual es una ventaja significativa en el contexto de este estudio. La robustez y la tendencia a no presentar

sobreajuste de los bosques aleatorios los convierte en una opción probablemente más adecuada para la complejidad del problema, teniendo en cuenta la reducida dimensión del conjunto de entrenamiento.

Modelos de Boosting: (*AdaBoost*, *GradientBoosting*, *LightGBM*, *XGBoost*): Dada la variabilidad y ruido debido a factores atmosféricos, heterogeneidad de la superficie, etc. de los datos de teledetección, y dada también la alta probabilidad de que la relación que se busca modelizar no sea lineal, se contempla el uso de algoritmos de *boosting*, que son ideales para generalizar y solucionar problemas no lineales. Estos algoritmos construyen un predictor fuerte a partir de la combinación secuencial de múltiples predictores débiles, corrigiendo los errores de los modelos previos, lo que es crucial para obtener un alto rendimiento predictivo en este contexto.

Máquinas de Vectores de Soporte (SVM): Se explora la aplicación de la técnica SVM para abordar posibles relaciones no lineales entre los datos de teledetección y la variable objetivo, es decir, la concentración de cianobacterias en los embalses. Se espera que estos modelos funcionen mejor que la regresión logística

Red neuronal simple: Dada la naturaleza del problema y la cantidad de datos disponibles, se determina que una red neuronal de alta complejidad no es apropiada. Se evalúan configuraciones sencillas de MLP, adecuadas para problemas de clasificación estándar. Aún así, la elección no es muy prometedora dada la limitada cantidad de datos de entrenamiento.

B.3. Selección de modelos validando con el embalse de El Val

El conjunto de datos obtenido a partir del Dataset 4 se utiliza para el entrenamiento, mientras que la validación de los modelos se realiza empleando los datos del embalse de El Val, proporcionados por la CHE, que se detallan en [A.1](#).

Se crean las estructuras de datos pertinentes para el entrenamiento y validación del problema de clasificación multiclase. Las clases objetivo se definen en función de los cuatro niveles de alerta de cianobacterias establecidos por la OMS, junto con una quinta clase que abarca concentraciones superiores a los niveles mencionados. Una vez creadas estas estructuras se aborda el desbalanceo de la clase o mediante el descarte aleatorio de muestras (*subsampling*). Se mantienen tantas muestras de esta clase como de la siguiente más frecuente, pues presenta más del doble de observaciones que la siguiente clase con más muestras.

Posteriormente, se configura un segundo conjunto de entrenamiento y validación, utilizando de igual forma los conjuntos del Dataset 4 y los datos de El Val, pero en este caso para un problema de **clasificación binaria**. Dado que el objetivo primordial del modelo a desarrollar es el de sistema de alerta, esta aproximación binaria agrupa las clases objetivo del problema multiclase en dos categorías: 'no alertar' y 'alertar'. Las muestras correspondientes a los niveles de alerta 0 y 1 se

agrupan en la clase 'no alertar', mientras que las muestras de las clases restantes, que representan los niveles de alerta más críticos, se agrupan en la clase 'alertar'.

Finalmente, se procede al entrenamiento y validación de los modelos detallados en la sección anterior, en el *notebook* `validacionConElVal`. Los resultados obtenidos se recogen en 2.8.

Para la clasificación multiclase la disponibilidad de datos por cada clase se manifiesta como un factor limitante, impidiendo que ningún modelo alcance prestaciones aceptables en la determinación del nivel de alerta específico. En cambio, para el problema en su versión binaria los resultados de gran parte de los modelos son satisfactorios, alcanzando precisiones superiores al 70 %. No obstante, también se observan resultados inesperados. Dada la limitada disponibilidad de datos del embalse de El Val, la representatividad de la validación es menor de lo deseado. A pesar de ello, se evidencia que las técnicas de *boosting* son las más apropiadas para la problemática, logrando estas las mejores precisiones. En cuanto a la red neuronal, se realiza primeramente la optimización de hiperparámetros (que para el resto de modelos se discutirá en la siguiente sección) y más adelante se entrena y valida para el problema binario únicamente. Esta decisión se toma porque, a diferencia de las otras técnicas estudiadas, cuyos hiperparámetros tienen un valor por defecto que es la base sobre la que mejorar al optimizarlos, al construir una red neuronal de cero no hay valores por defecto, por lo que no se pueden comprobar dichos valores para después optimizarlos. Como cabría esperar queda algo sobreajustada, lo que tiene sentido dado el desbalanceo entre la clase 0 y la 1 en el problema binario, además de la dimensión reducida y por ello escasa variabilidad de los datos del conjunto de entrenamiento. Se debe estudiar mejorar la regularización para evitar este sobreajuste.

B.4. Optimización de hiperparámetros

Tras el entrenamiento y la validación de los modelos considerados, se procede a la optimización de sus hiperparámetros con el objetivo de mejorar su rendimiento. Inicialmente, se exploran diversas estrategias de optimización con el modelo de regresión logística debido a su simplicidad computacional. Para ello, se estudian las siguientes aproximaciones:

- **Búsqueda en malla empleando GridSearchCV de scikit-learn con *K-Folds* estratificada:** Estas técnicas son ampliamente conocidas y utilizadas, y para los conjuntos de datos de reducido tamaño que estamos empleando es una elección atractiva, ya que entre otras cosas se garantiza que la representación de las clases se preserve consistentemente en cada partición. En otras palabras, esta técnica es prometedora porque se asegura de que en cada pliegue que se realiza para entrenar y validar haya muestras de cada clase. Dado que en los conjuntos de entrenamiento y validación hay clases con un reducido número de muestras, no tener esto en cuenta podría resultar en pliegues sin muestras de alguna clase, empeorando la optimización y en

consecuencia la capacidad predictiva del modelo.

Además, esta opción es la más sencilla de implementar, pues está especialmente integrada con el resto de modelos de la librería scikit-learn.

- **Librería Hyperopt:** Hyperopt implementa algoritmos de optimización bayesiana para buscar los hiperparámetros óptimos de manera más eficiente que la búsqueda en malla con `GridSearchCV`, explorando el espacio de búsqueda de forma inteligente y priorizando combinaciones prometedoras.
- **Librería Optuna:** *Optuna* es un framework de optimización de hiperparámetros que utiliza la optimización bayesiana y otras estrategias de búsqueda avanzada. Destaca por su flexibilidad, permitiendo definir espacios de búsqueda dinámicos y algoritmos de poda temprana para detener evaluaciones poco prometedoras.

Tras una evaluación comparativa, se selecciona la validación cruzada con `GridSearchCV` de la biblioteca scikit-learn como la estrategia principal. Se implementa una función denominada `grid_search_y_evaluacion` que automatiza este proceso. Esta función recibe como argumentos un modelo de aprendizaje automático y un diccionario con los rangos de valores para cada hiperparámetro, y su propósito es encontrar la combinación óptima de hiperparámetros mediante validación cruzada con *K-Folds* para los datos de entrenamiento.

Esta función se aplica para optimizar los hiperparámetros de todos los modelos considerados, a excepción de la red neuronal, cuyos hiperparámetros son optimizados manualmente.

Los resultados obtenidos tras la optimización no muestran mejoras sustanciales. Durante la validación cruzada, empleando exclusivamente los datos de entrenamiento, se observan en algunos modelos precisiones superiores a las alcanzadas con el conjunto de validación. Sin embargo, al reentrenar y validar estos modelos optimizados utilizando los datos del embalse del Val, no se consigue, en ningún caso, superar los resultados previos a la optimización. Este fenómeno reitera el desafío inherente a la limitada cantidad de datos disponibles para la validación con las muestras del embalse de El Val. La escasez de muestras implica que cualquier desviación mínima del modelo puede repercutir significativamente en la clasificación, alterando de manera drástica las métricas de rendimiento y dificultando la evaluación del rendimiento de estos modelos.

Bibliografía

- Braaten, J. D., Cohen, W. B., & Yang, Z. (2015). Automated cloud and cloud shadow identification in Landsat MSS imagery for temperate ecosystems. *Remote Sensing of Environment*, 169, 128-138. <https://doi.org/10.1016/j.rse.2015.08.006> (vid. pág. 35).
- Chorus, I., & Bartram, J. (1999, enero). *Toxic Cyanobacteria in Water - A guide to their public health consequences, monitoring and management*. (Vid. pág. 2).
- Gupta, S., Gelbart, E., Gupta, R., Wetstone, K., & Dorne, E. (2024). Cyanobacteria Aggregated Manual Labels Dataset (NASA and DrivenData) [Dataset]. Consultado el 22 de junio de 2025, desde <http://dx.doi.org/10.5067/SeaBASS/CAML/DATA001> (vid. págs. 18, 57).
- Huang, C., Chen, Y., Zhang, S., & Wu, J. (2018). Detecting, Extracting, and Monitoring Surface Water From Space Using Optical Sensors: A Review. *Reviews of Geophysics*, 56(2), 333-360. <https://doi.org/10.1029/2018RG000598> (vid. pág. 36).
- Skakun, S., Wevers, J., Brockmann, C., Doxani, G., Aleksandrov, M., Batič, M., Frantz, D., Gascon, F., Gómez-Chova, L., Hagolle, O., López-Puigdollers, D., Louis, J., Lubej, M., Mateo-García, G., Osman, J., Peressutti, D., Pflug, B., Puc, J., Richter, R., ... Žust, L. (2022). Cloud Mask Intercomparison eXercise (CMIX): An evaluation of cloud masking algorithms for Landsat 8 and Sentinel-2. *Remote Sensing of Environment*, 274, 112990. <https://doi.org/10.1016/j.rse.2022.112990> (vid. pág. 35).
- Xue, K., Ma, R., Zhu, G., Hu, M., Cao, Z., Xiong, J., Zhang, Y., Xu, J., Huang, Z., & Wu, Y. (2024). A comprehensive time-series dataset linked to cyanobacterial blooms in Lake Taihu (Version V2). <https://doi.org/10.5281/zenodo.13917285> (vid. págs. 18, 57).
- Zupanc, A. (2017, 19 de diciembre). *Improving Cloud Detection with Machine Learning*. Sentinel Hub. Consultado el 21 de junio de 2025, desde <https://medium.com/sentinel-hub/improving-cloud-detection-with-machine-learning-c09dc5d7cf13> (vid. pág. 35).